

UNIVERSIDADE FEDERAL FLUMINENSE  
INSTITUTO DO NOROESTE FLUMINENSE DE EDUCAÇÃO SUPERIOR  
DEPARTAMENTO DE CIÊNCIAS EXATAS, BIOLÓGICAS E DA TERRA  
GRADUAÇÃO EM LICENCIATURA EM COMPUTAÇÃO

# Combinando abordagens supervisionadas e não-supervisionadas para segmentação de imagens de úlceras em membros inferiores

Wellington de Souza Silva

Orientador: Prof. Dr. Marcos Vinícius Naves Bêdo

Coorientador: Prof. Dr. Rodrigo Erthal Wilson



Wellington de Souza Silva

**Combinando abordagens supervisionadas e  
não-supervisionadas para segmentação de imagens de úlceras  
em membros inferiores**

Trabalho Final de Curso apresentado ao curso de Licenciatura em Computação da Universidade Federal Fluminense, *campus* Santo Antônio de Pádua, como requisito parcial à conclusão de graduação. Área de concentração: Processamento de Imagens/Banco de Dados.

**Orientador:** Prof. Dr. Marcos V. N. Bêdo.

**Coorientador:** Prof. Dr. Rodrigo E. Wilson.

Universidade Federal Fluminense  
Instituto do Noroeste Fluminense de Educação Superior  
Licenciatura em Computação

Santo Antônio de Pádua - RJ

Julho - 2019

Ficha catalográfica automática - SDC/BINF  
Gerada com informações fornecidas pelo autor

S586c Silva, Wellington de Souza  
Combinando abordagens supervisionadas e não-supervisionadas para segmentação de imagens de úlceras em membros inferiores / Wellington de Souza Silva ; Prof. Dr. Marcos Vinícius Naves Bêdo, orientador ; Prof. Dr. Rodrigo Erthal Wilson, coorientador. Santo Antônio de Pádua, 2019.  
86 f.

Trabalho de Conclusão de Curso (Graduação em Computação)-Universidade Federal Fluminense, Instituto do Noroeste Fluminense de Educação Superior, Santo Antônio de Pádua, 2019.

1. Imagens de feridas. 2. Superpixels. 3. MLP. 4. DBSCAN. 5. Produção intelectual. I. Bêdo, Prof. Dr. Marcos Vinícius Naves, orientador. II. Wilson, Prof. Dr. Rodrigo Erthal, coorientador. III. Universidade Federal Fluminense. Instituto do Noroeste Fluminense de Educação Superior. IV. Título.

CDD -

Bibliotecário responsável: Maria Dalva Pereira de Souza - CRB7/7044

Wellington de Souza Silva

## Combinando abordagens supervisionadas e não-supervisionadas para segmentação de imagens de úlceras em membros inferiores

Trabalho Final de Curso apresentado ao curso de Licenciatura em Computação da Universidade Federal Fluminense, *campus* Santo Antônio de Pádua, como requisito parcial à conclusão de graduação. Áreas de concentração: Processamento de Imagens/Banco de Dados.

Aprovado em: \_\_/\_\_/\_\_\_\_.

### **Banca Examinadora**

---

Orientador: Prof. Dr. Marcos Vinícius Naves Bêdo  
INFES/UFF

---

Coorientador: Prof. Dr. Rodrigo Erthal Wilson  
INFES/UFF

---

Prof. Dr. Gustavo Silva Semaan  
INFES/UFF

---

Prof. Dr. Rodolfo Alves de Oliveira  
INFES/UFF



## Agradecimentos

Agradeço aos meus familiares pelo apoio prestado, em especial à minha mãe, por sempre acreditar em meu potencial e por estar ao meu lado. À Jainne dos Santos Rosa, que é essencial para a elaboração desse trabalho e em minha vida. Aos servidores do Instituto do Noroeste Fluminense de Educação Superior, com destaque para os professores Marcos Vinícius Naves Bêdo e Rodrigo Erthal Wilson, que orientaram esse trabalho. Finalmente, agradeço aos amigos que estiveram presentes durante a minha graduação.





## Resumo

A segmentação de tecidos de fotografias de úlceras crônicas em membros inferiores é uma abordagem não intrusiva para análises dermatológicas. Este trabalho envolve o estudo e implementação de técnicas de processamento digital de imagens aplicadas às imagens de úlceras em membros inferiores, com o objetivo de segmentar e identificar as diversas classes de tecidos existentes nesse tipo de lesão. Para esse propósito foram desenvolvidas uma solução *ad-hoc* e uma solução baseada em aprendizado de máquina. Essa última, denominada 2PLA, é um método que combina estratégias de aprendizado supervisionado e não supervisionado para melhorar a segmentação das imagens dermatológicas. Dada uma foto de úlcera capturada de acordo com um protocolo médico fixo, a primeira fase do sistema realiza uma classificação de pontos de interesse, enquanto filtros de pré-processamento são empregados para suavizar o ruído da imagem. A imagem limpa é enviada posteriormente para uma segunda fase que consiste em divisão e conquista, baseada em um algoritmo de construção de superpixels. O método 2PLA divide membro inferior em regiões de interesse com bordas bem definidas e agrupa os superpixels utilizando o algoritmo DBSCAN, que é baseado em similaridade. As duas fases do 2PLA foram avaliadas em um conjunto real de feridas dermatológicas. Avaliações empíricas em amostras representativas de até 100.000 pontos mostram que uma rede neural artificial Perceptron Multi-Layer com o algoritmo de treinamento Levenberg-Marquardt (Coeficiente de Kappa-Cohen = 0,971, Sensibilidade = 0,98 e Especificidade = 0,98) supera outros classificadores como a primeira fase da 2PLA. Além disso, ensaios experimentais com o DBSCAN e cinco funções de distância ( $L_1$ ,  $L_2$ ,  $L_\infty$ , Canberra e BrayCurtis) indicam que a função  $L_1$  gera menos grupos em comparação a outras funções, percebendo-se um decaimento exponencial da quantidade de grupos em função da taxa de similaridade. O critério do “cotovelo” foi empregado para encontrar o limite do DBSCAN com a função  $L_1$  como parametrização da segunda fase do sistema. A avaliação final do 2PLA com as duas fases devidamente configuradas em um conjunto rotulado de imagens de úlcera indica que os tecidos foram corretamente segmentados dentro de uma razão de erro absoluto médio de 0,05, o que ilustra o impacto de eficácia do método 2PLA para a segmentação de feridas.

**Palavras-chave:** Imagens de feridas, Superpixels, MLP, DBSCAN



# Abstract

Tissue segmentation in photographs of lower limb chronic ulcers is a non-intrusive approach that supports dermatological analyses. This study involves the design and implementation of digital image processing techniques applied to ulcer images in lower limbs, aiming at identifying and segmenting different classes of tissues within dermatological wounds. Accordingly, two solutions are discussed: one ad-hoc proposal, and one machine-learning-based approach, called 2PLA. The latter solution combines supervised and unsupervised learning strategies for enhancing the segmentation of dermatological ulcers. Given an ulcer photo captured according to a fixed protocol, 2PLA first phase performs a pixelwise classification of points of interest, whereas pre-processing filters are employed for the smoothing of image noise. The cleaned image is further sent to the 2PLA divide-and-conquer second phase. It builds upon SLIC superpixel construction algorithm for dividing the lower limb into regions of interest with well-defined borders, and clusters the superpixels by taking advantage of the similarity-based DBSCAN algorithm. We set up the phases of the method by using a real annotated set of dermatological wounds, and empirical evaluations on representative samples up to 100,000 points showed a compact Multi-Layer Perceptron with Levenberg–Marquardt training algorithm (Cohen-Kappa Coefficient = 0.971, Sensitivity = 0.98, and Specificity = 0.98) outperformed other classifiers as 2PLA first phase. Additionally, experimental trials on DBSCAN with five distance functions ( $L_1$ ,  $L_2$ ,  $L_\infty$ , Canberra, and BrayCurtis) indicated  $L_1$  function provided fewer groups in comparison to the competitors, and the number of clusters was an exponential decay to the similarity ratio. Accordingly, we used the “elbow” criterion for finding the  $L_1$ -based DBSCAN threshold as the 2PLA second phase parameterization. We evaluated the fine-tuned setting of 2PLA over a labeled set of ulcer images, and wounded tissues were segmented within a 0.05 Mean Absolute Error ratio. These results illustrate the method efficacy for wound segmentation.

**Keywords:** Wound images, Superpixels, MLP, DBSCAN



## Lista de ilustrações

Figura 1 – Espectro eletromagnético . . . . .	6
Figura 2 – Diagrama de cromaticidade . . . . .	7
Figura 3 – Modelos de cores . . . . .	8
Figura 4 – Exemplo da aplicação do filtro da mediana. . . . .	11
Figura 5 – Exemplo de superpixels gerados pelo método SLIC . . . . .	15
Figura 6 – Exemplo de fronteira de decisão para duas classes . . . . .	17
Figura 7 – Exemplo de matriz de confusão para duas classes . . . . .	18
Figura 8 – Nível de concordância do Coeficiente de Cohen–Kappa . . . . .	20
Figura 9 – Topologia de uma MLP totalmente conectada . . . . .	21
Figura 10 – Conexão <i>feedforward</i> e <i>backpropagation</i> . . . . .	22
Figura 11 – Exemplos de formatos de agrupamento gerados pelo DBSCAN . . . . .	24
Figura 12 – Exemplo do algoritmo DBSCAN . . . . .	27



## Lista de tabelas

Tabela 1 – Conjunto demonstrativo para o método do DBSCAN . . . . .	25
Tabela 2 – Matriz de distâncias para o DBSCAN . . . . .	26
Tabela 3 – Síntese da matriz de distância . . . . .	26
Tabela 4 – Trabalhos relacionados revisados . . . . .	28





## Lista de abreviaturas e siglas

AM	<i>Aprendizado de Máquina</i>
ANN	<i>Rede Neural Artificial</i>
BN	<i>Bayes-Net</i>
CIE	<i>Comissão Internacional de Iluminação</i>
DBSCAN	<i>Agrupamento Espacial Baseado em Densidade de Aplicações com Ruído (Density-Based Spatial Clustering of Applications with Noise)</i>
DT	<i>Árvore de Decisão</i>
HSI	<i>Modelo de cores HSI</i>
kNN	<i>k-Vizinhos mais próximos</i>
LAB	<i>Modelo de cores LAB</i>
LM	<i>Levenberg-Marquardt</i>
MAE	<i>Erro Absoluto Médio</i>
MSE	<i>Erro Quadrático Médio</i>
MLP	<i>ANN Perceptron em Multicamadas (Multi-Layer Perceptron)</i>
NB	<i>Naïve-Bayes</i>
RF	<i>RandomForest</i>
RT	<i>RandomTree</i>
RGB	<i>Modelo de cores RGB</i>
RPROP	<i>Resilient Propagation</i>
SVM	<i>Máquina de Vetores de Suporte</i>
TN	<i>Verdadeiro Negativo</i>
TP	<i>Verdadeiro Positivo</i>
FN	<i>Falso Negativo</i>
FP	<i>Falso Positivo</i>
SLIC	<i>Agrupamento Iterativo Linear Simples (Simple Linear Iterative Clustering)</i>



## Lista de símbolos

$P_i$	Pixel
$I$	Imagem digital
$\oplus$	Dilatação morfológica
$\circ$	Abertura morfológica
$\ominus$	Erosão morfológica
$\bullet$	Fechamento morfológico
$\phi$	Classificador
$T$	Conjunto de treinamento
$L$	Conjunto discreto e disjunto de rótulos
$\kappa$	Coeficiente de Cohen-Kappa
$\lambda_e$	Taxa hipotética de aceitação
$\lambda_o$	Taxa de aceitação relativa
$\mathcal{P}$	Domínio do pixel
$\mu$	Média simples
$\bar{\mu}$	Média ponderada
$L_p$	Família Minkowski de funções
$L_1$	Função de distância City-Block
$L_2$	Função de distância Euclideana
$L_\infty$	Função de distância de Chebyshev
$\delta$	Função de distância métrica
$\xi$	Limite de similaridade (distância máxima)
$\sigma^2$	Variância
$\mathcal{S}$	Superpixel
$\mathcal{C}$	Conjunto de grupos
$\theta$	Método de agrupamento



# Sumário

<b>1</b>	<b>Introdução</b>	<b>1</b>
1.1	Motivação e Contexto	1
1.2	Modelo de quatro cores	2
1.3	Diagnóstico Assistido por Computador	3
1.4	Objetivos	4
1.5	Organização da Monografia	5
<b>2</b>	<b>Conceitos Preliminares e Levantamento Bibliográfico</b>	<b>6</b>
2.1	Teoria de cores	6
2.2	Modelos de cores	7
2.2.1	Modelo RGB	7
2.2.2	Modelo HSI	8
2.2.3	Modelo LAB	9
2.3	Imagem Digital	10
2.3.1	Filtro da mediana	11
2.3.2	Método de Otsu	11
2.3.3	Morfologia Matemática	13
2.3.4	Superpixels	14
2.4	Aprendizado de Máquina	16
2.4.1	Classificação de Dados	17
2.4.2	Redes Neurais Artificiais	20
2.4.3	Agrupamento de Dados	22
2.4.4	DBSCAN	24
2.5	Trabalhos relacionados	28
2.6	Conclusões parciais	28
<b>3</b>	<b>Material e Métodos</b>	<b>31</b>
3.1	Material: Conjunto de Dados e Ferramentas	31
<b>4</b>	<b>Experimentos e Resultados</b>	<b>33</b>
<b>5</b>	<b>Conclusão</b>	<b>33</b>
5.1	Dificuldades Encontradas	35
5.2	Publicação	36
5.3	Premiação	36
5.4	Trabalhos Futuros	36
	<b>REFERÊNCIAS</b>	<b>37</b>

# 1 Introdução

## 1.1 Motivação e Contexto

Úlceras em membros inferiores são lesões dermatológicas que tendem a se originar da deficiência no fluxo sanguíneo na região das feridas da pele (PEREIRA et al., 2011). Diversos fatores contribuem para sua formação, tais como diabetes, lesões, doenças vasculares, tumores, infecções e insuficiência venosa arterial (RAMELET, 2001).

Em particular, as úlceras que correspondem a ampla maioria dos casos de ulceração podem ser detalhadas de acordo com as seguintes características:

- Venosa (estase): São lesões que surgem oriundas de veias varicosas e também de trombose venosa profunda. Podem evoluir para lesões crônicas, caso não se cicatrizem em poucas semanas (ABBADE; LASTORIA, 2005). Esse tipo resulta em uma morbidade significativa e ocasiona sequelas.
- Arterial (isquêmica): São lesões que têm sua origem associada a doenças arteriais periféricas, tabagismo e diabetes. Geralmente o início da lesão é consequência da diminuição (ou obstrução total) do fluxo sanguíneo arterial nos membros inferiores. Com o fluxo comprometido, há a necrose do tecido, o que causa a ulceração. Esse tipo de úlcera costuma ser predominante em indivíduos do sexo masculino.
- Neuropática: São lesões que são comuns na região dos pés do paciente, área de pressão, como causas estão a diabete melito com dificuldade para cicatrização. Esse tipo de ulceração pode levar à amputação da região em vários casos.

O diagnóstico dessas lesões é realizado por dermatologistas, por meio dos chamados métodos macroscópico ou avaliações visuais da lesão, dado que o aspecto da úlcera expõe muitos de seus atributos importantes (PEREIRA et al., 2011). A precisão desse método de avaliação está associada à habilidade visual do especialista. Entretanto, sabe-se que existem limitações associadas a esse método de avaliação, especialmente os ligados ao desgaste da rotina clínica e a variação da percepção de cada dermatologista (MAGLOGIANNIS; PAVLOPOULOS; KOUTSOURIS, 2005). Assim, o tratamento da ulceração pode ser afetado por essas imprecisões visuais, tornando necessário o uso de mecanismo intrusivos de avaliação, como a biópsia.

O tratamento para a lesão visa fechar e evitar o reaparecimento da úlcera. Existem diversos procedimentos para a cicatrização da lesão, como, por exemplo: intervenção cirúrgica, medicamentos e terapias. Esses métodos, são normalmente combinados de acordo com o prognóstico visual do especialista. Após o tratamento da lesão, a preocupação passa ser com o seu reaparecimento, com maior probabilidade de ocorrência nos primeiros anos (pós-tratamento). Portanto devem-se tomar medidas de prevenção, tais como, fisioterapia e o uso de meias elásticas de compressão médica. Um fato importante é que os procedimentos preventivos também variam de acordo com o tipo da úlcera dermatológica (ABBADE; LASTORIA, 2005).

Visualmente, o aspecto da úlcera é caracterizado por seu formato irregular, com bordas nítidas e rígidas. Em estados iniciais, a ulceração, apresenta-se como uma lesão superficial, que tende a se aprofundar com o decorrer do tempo. A fisionomia da úlcera também demonstra particularidades, como sua composição, textura e tonalidade (DORILEO et al., 2010). Nesta fisionomia, é possível definir quais as particularidades da lesão e os tecidos que a compõem, *i.e.*, granulação, fibrina, necrose e tecido misto (PEREYRA et al., 2014). Esses tipos de tecido podem ser descritos como:

- Granulação: Inclui a composição de brotos capilares, que se organizam de diversas formas, e se caracteriza por estar presente durante o início da cicatrização da lesão;
- Fibrina: É uma agregação das plaquetas e de líquidos serosos na região onde houve rompimento de vasos sanguíneos. Esse tecido constitui um tipo de coágulo sanguíneo;
- Necrose: É um tecido composto por células mortas e descartadas, que pode indicar como a úlcera está atingindo os tecidos orgânicos;
- Tecido misto: São compostos de uma mistura dos três tecidos anteriores, que ocorrem ao mesmo tempo.

Cada tecido possui seus atributos característicos em termos de cor e textura predominante (PEREIRA et al., 2011). Por exemplo, tecidos granulosos são compostos pela cor vermelha; tecidos de fibrina predominantemente formados pela tonalidade amarelada; tecidos necrose tem sua formação caracterizada pela cor preta e marrom escuro. Por último, a mistura de tecidos é composta diversos fragmentos de cores e texturas (CHINO et al., 2018).

Portanto, com o objetivo de auxiliar a análise macroscópica do dermatologista feita para a lesão de úlcera, nossa proposta é a definição de um sistema de processamento de imagens digitais automatizado (GONZALEZ; WOODS, 2008). Uma consequência indireta, porém benéfica, é que o uso desses sistemas permitem tanto reproduzir a análise, quando justificar em termos algorítmicos o método de detecção. Abordagens existentes identificam cores e texturas predominantes na lesão e as associam com o tipo de tecido (CHINO et al., 2018; BLANCO et al., 2016). O método a ser discutido neste trabalho é complementar ao uso dessas abordagens, no sentido que não assume a existência de nenhuma classe de tecido, mas os agrupa de acordo com padrões implícitos nos tecidos lesionados.

## 1.2 Modelo de quatro cores

Métodos de processamento de imagens aplicados no domínio de úlceras dermatológicas, visam rotular os diferentes tipos de tecidos da lesão, de acordo com sua cor e textura. Levando em conta que os tecidos qualificados na análise macroscópica incluem *granulação*, *fibrina*, *necrose* e *misto*, é possível determinar diversas etapas com o objetivo auxiliar o diagnóstico e

tratamento de úlceras em membros inferiores (BLANCO et al., 2016). O processo do tratamento é dividido em três etapas, de acordo com a quantidade de cada um dos tecidos:

1. Inflamação: É a primeira resposta protetora do sistema imunológico, resultando em uma vermelhidão causada pelo aumento do fluxo sanguíneo e demais fluxos corporais que migram para região da ferida e podem aumentar a temperatura da região.
2. Formação de tecido: Caracterizada por brotos capilares e fibroblastos. Trata da formação de tecido de granulação, que dá início ao processo de cicatrização (que não é, necessariamente, definitivo).
3. Remodelagem: Essa estágio indica a remodelagem da cicatrização e a re-epitelização, que é o crescimento de tecido orgânico (pele saudável) nas bordas da feridas, sendo um acontecimento final no processo de reparo.

### 1.3 Diagnóstico Assistido por Computador

Sistemas de Diagnóstico Assistido por Computador (CAD - *Computer-Aided Diagnosis*) traz em diversas vantagens à avaliação macroscópica, minimizando eventuais desvantagens à percepção do especialista no momento da avaliação visual, tais como: iluminação do ambiente, desgaste físico e diagnósticos prévio divergente entre diferentes profissionais (MAGLOGIAN-NIS; PAVLOPOULOS; KOUTSOURIS, 2005). O propósito de um sistema CAD nesse caso, é auxiliar no diagnóstico e o prognóstico de lesões. Sistemas CAD baseados puramente em aprendizado de máquina já são capazes de identificar e diagnosticar lesões com qualidade próxima ou superior a dermatologistas humanos (ESTEVA et al., 2017). Entretanto, para úlceras dermatológicas, objeto de estudo desse trabalho, ainda não existem sistemas CAD com resultados dessa magnitude, e proporcionar maior agilidade, eficiência, confiabilidade replicação fácil dos prognósticos indicados ainda é uma dificuldade (BLANCO et al., 2016; KAVITHA; SUGANTHI; RAMAKRISHNAN, 2017; CHINO et al., 2018). Uma ferramenta CAD aplicada ao domínio de úlceras dermatológicas deve ser focada na segmentação dos tecidos para auxiliar o especialista humano no diagnóstico da lesão (ODUNCU et al., 2004; PEREYRA et al., 2014). De acordo com Bedo et al. (2015) os pontos e objetivos da maioria das ferramentas CAD para úlceras dermatológicas na literatura se baseiam em quatro processos:

- Segmentação de imagem: Processo de separação da área de interesse (pele) e descarte de partes irrelevantes (fundo), bem como separação de possíveis tipos de tecidos lesionados;
- Extração de características: Processo usado para representar segmentos de uma imagem, como vetores numéricos multidimensionais;
- Seleção de características: Processo usado para selecionar as dimensões mais representativas dos vetores numéricos multidimensionais que foram extraídos (dos pedaços) da imagem ou fotografia original da úlcera;



- Classificação da imagem: É o processo utilizado para rotular cada um dos pedaços da imagem representados como vetores de dimensões significativas.

Ainda que esses quatro processos sejam o centro do funcionamento de sistemas CAD, técnicas de processamento de imagens podem ser empregadas com a finalidade de melhorar o resultado em qualquer estágio do processamento e auxiliar na identificação de particularidades das lesões (GONZALEZ; WOODS, 2008). Portanto, um sistema CAD para úlceras dermatológicas deve ter por objetivo fornecer uma solução para processamento e análise de imagens médicas específicas. Uma limitação no processamento é a aquisição da imagem, que no caso de úlceras dermatológicas, pode ser contornado com o uso de um plano de fundo, ângulo, foco e distância fixos (PEREYRA et al., 2014).

Assim, a solução proposta deve permitir a separação e quantificação de conteúdos relevantes das imagens, como as regiões da úlcera. Para cada região deve ser possível determinar padrões dos tecidos presentes na lesão. A abordagem CAD proposta será inspirada em sistemas de trabalhos anteriores (PEREIRA et al., 2011; BLANCO et al., 2016; KAVITHA; SUGANTHI; RAMAKRISHNAN, 2017; CHINO et al., 2018). Estes sistemas já auxiliam o dermatologista ao informar medidas estatísticas e ao recuperar casos similares por conteúdo.

No entanto, nenhum dos estudos anteriores analisou o problema de segmentação de úlceras dermatológicas tanto da perspectiva supervisionada quanto da perspectiva não-supervisionada, no sentido de usar uma abordagem em duas fases para separar conteúdos relevantes da lesão e detecção de padrões em trechos de tecidos *não lesionados*. Em particular, os trabalhos existentes, não combinam técnicas de pré-processamento e classificadores supervisionados para descartar partes irrelevantes da área da lesão, mas sim para rotular as áreas lesionadas em si (CHINO et al., 2018). Nossa premissa é, primeiro, combinar esses métodos para descartar padrões desimportantes para a análise dos tecidos ulcerados e, só depois, buscar padrões nos tecidos segmentados sem considerar rótulos ou comportamentos específicos.

## 1.4 Objetivos

Há duas metas essenciais para que se possa atingir o objetivo proposto. A primeira é a separação entre pele do paciente e o fundo da imagem, enquanto que a segunda é a de agrupar os tecidos de acordo com padrões implícitos entre eles. Portanto, os objetivos específicos desse trabalho, consistem em:

1. Segmentação da imagem entre pele e outros – Essa tarefa é abordada considerando técnicas de processamento de imagens e de aprendizado de máquina supervisionado.
2. Agrupamento dos tecidos lesionados – Após a eliminação de áreas desimportantes da análise, buscar-se-á combinar técnicas de processamento de imagens (geração de *superpixels*) e técnicas de aprendizagem de máquina não-supervisionadas para agrupar os tecidos com padrões similares, porém não explícitos.

## 1.5 Organização da Monografia

Esse documento está organizado em cinco capítulos. Além desse, os demais capítulos incluem o seguinte conteúdo:

- O Capítulo 2 apresenta o arcabouço conceitual sobre os métodos empregados e uma comparação dos trabalhos relacionados. São revisados conceitos de morfologia matemática, classificação e agrupamento, com destaque especial para o método de agrupamento particional DBSCAN.
- O Capítulo 3 explica a metodologia adotada, as imagens utilizadas, a abordagem implementada, além dos testes realizados e resultados obtidos. São discutidas duas soluções implementadas, uma solução *ad-hoc* baseada em processamento de imagens e uma alternativa baseada em aprendizado de máquina.
- O Capítulo 4 apresenta os resultados sobre avaliações experimentais sobre os métodos propostos. As avaliações são conduzidas sobre um conjunto de dados real.
- O Capítulo 5 apresenta as conclusões derivadas das observações realizadas, um resumo das publicações derivadas e direções sobre trabalhos futuros.

## 2 Conceitos Preliminares e Levantamento Bibliográfico

Este capítulo aborda os princípios empregados na execução desse trabalho. Em particular, são discutidos dois temas: processamento digital de imagens e aprendizado de máquina. Além disso, ao final, é feito um levantamento bibliográfico que resume os avanços da literatura na análise de imagens de úlcera em membros inferiores.

O tópico de processamento de imagens digitais inclui uma discussão sobre teoria das cores, filtros espaciais, métodos de limiarização e morfologia matemática. A teoria de cores é a base para diversos modelos de cores, que prezam por representar tonalidades de cores em um determinado subespaço próprio. O modelo RGB retrata as cores como um cubo tridimensional, cujos eixos são as cores vermelha, verde e azul. Já, o modelo HSI descreve as cores em um sistema em formato de cilindro vertical, que permite combinar os atributos de matiz, saturação e o valor de intensidade. Por fim, o modelo LAB permite descrever as cores com semântica euclidiana e estabelece duas transformações para representar cada uma de suas três coordenadas.

A revisão sobre aprendizado de máquina possui dois componentes principais, a saber: aprendizado supervisionado e aprendizado não-supervisionado. Nesse trabalho ambos os componentes serão usados para finalidades distintas. O primeiro para classificar o fundo e a pele de imagens de úlcera e o segundo para agrupar tipos de tecido diferentes dentro de uma mesma lesão ulcerada.

### 2.1 Teoria de cores

As cores perceptíveis aos olhos são uma reflexão da luz em objetos quaisquer. A luz está contida no espectro eletromagnético, situado aproximadamente na faixa entre 400 até 700nm, como ilustrado na Figura 1. As cores percebidas pelos olhos possuem um subintervalo no espectro eletromagnético (GONZALEZ; WOODS, 2008). Por exemplo, a tonalidade “vermelha” está compreendida no comprimento de onda entre 635 até 700nm.




Figura 1 – Espectro eletromagnético. Adaptado de Gonzalez e Woods (2008).

O olho humano contém dois tipos de células especializadas em detectar cores: os bastonetes e os cones. Em particular, os cones são capazes de identificar certos comprimentos de ondas de acordo com três propriedades importantes da luz visível para a formação das cores: radiância, luminância e brilho (GONZALEZ; WOODS, 2008).

1. Radiância: Indica a quantidade total de energia que flui da fonte de luz, em *watts*,
2. Luminância: Medida em *lumens*, indica a quantidade de energia que um observador percebe de uma fonte, e
3. Brilho: Descritor subjetivo, incorpora a noção acromática de *intensidade*, um dos principais fatores da percepção das cores.

A fim de quantificar as cores, pode-se fazer uso do padrão de cromaticidade estabelecido pela Comissão Internacional de Iluminação (CIE)<sup>1</sup>, ilustrado na Figura 2. Esse diagrama representa inúmeras cores de acordo com a composição das coordenadas de cromaticidade do gráfico (GONZALEZ; WOODS, 2008).

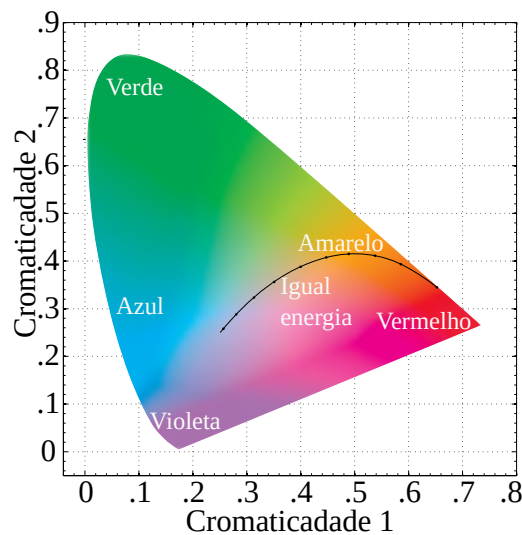


Figura 2 – Diagrama de cromaticidade. Adaptado de Gonzalez e Woods (2008).

## 2.2 Modelos de cores

Modelos de cores são uma especificação de coordenadas que delimitam um subespaço no padrão CIE, com o objetivo de representar cada cor como um ponto (SONKA; HLAVAC; BOYLE, 1993). Os modelos de interesse desse trabalho são: RGB, HSI e LAB.

### 2.2.1 Modelo RGB

Este modelo de cores utiliza um espaço tridimensional, com a finalidade de representar as cores em três dimensões, denominadas vermelho, verde e azul (Figura 3(a)). Todas as cores nesse modelo têm a propriedade de serem representadas como uma composição vetorial, onde se emprega a combinação dos eixos vermelho, verde e azul para a geração de todas as cores. Os pontos nesse espaço tridimensional, além de formarem cores visíveis também podem ser vistos como a estrutura de dados denominada *pixel*. Um pixel é a estrutura de dados que corresponde a

<sup>1</sup> <[www.cie.co.at/](http://www.cie.co.at/)>

unidade *atômica* de uma imagem digital (MCCAMY et al., 1976; SONKA; HLAVAC; BOYLE, 1993), de acordo com a Definição 1.

**Definição 1.** [Pixel] Um pixel  $P_i = \{r_i, g_i, b_i\}$  é constituído por uma tupla no espaço de cores RGB, onde  $r_i$  é a componente do eixo vermelho,  $g_i$  é a componente do eixo verde e  $b_i$  é a componente do eixo azul.

A *profundidade* do pixel está computacionalmente associada ao número de cores gerados por esse modelo, medida em termos do número de bits  $b$  que são empregados para retratar cada componente vetorial. A representação de uma imagem em padrões conhecidos se dá normalmente por oito bits de profundidade, como nos padrões JPEG, descrito por Ahmed, Natarajan e Rao (1974), e PNG, detalhado por Boutell (1997). Como os oito bits são definidos para cada camada, ao se multiplicar todas as três camadas obtém-se a profundidade total do pixel de 24-bits. Imagens de 24-bits são denominadas *full-color* e permitem a representação de  $(2^8)^3 = 16.777.216$  cores distintas (CHANG; REID, 1996; GONZALEZ; WOODS, 2008).




Figura 3 – Modelos de cores. (a) Modelo RGB. (b) Modelo HSI. (c) Modelo LAB. Adaptado de Gonzalez e Woods (2008).

### 2.2.2 Modelo HSI

O modelo RGB se inspira no sistema visual humano ao buscar representar a forma na qual as células do olho percebem as cores. Contudo, esse modelo pode não ser adequado para descrever as cores de objetos, em termos de interpretação da luz visível, pois associa cores a uma combinação vetorial. Por outro lado, o modelo HSI ilustra as tonalidades como matiz, saturação e intensidade e permite a descrever a luz visível (GONZALEZ; WOODS, 2008). Os componentes do modelo são:

- Hue (Matiz): Atributo associado ao comprimento de onda dominante dentro da mistura da luz. A matiz representa a cor percebida pelo observador. Ao se mencionar as cores, *i.e.* vermelho ou amarelo, normalmente tem-se a referência à matiz.
- Saturação: Refere-se à (ausência da) quantidade de luz branca que compõe a matiz. As cores denominadas puras, são totalmente saturadas e possuem a combinação de cores da matiz e luz branca. Por exemplo, “cor-de-rosa” pode ser a combinação de “vermelho” com “branco”. O grau de saturação é inversamente proporcional a quantidade de luz branca adicionada a uma cor qualquer.

- **Intensidade:** Incorpora a noção acromática de intensidade, isto é, uma propriedade para permitir descrever a “sensação” das cores.

Ao contrário do modelo de cores RGB, o HSI é expresso no formato de um cilindro vertical. Na base do cilindro ficam as cores escuras e no topo ficam as cores mais claras. O eixo da Matiz representa as cores em coordenadas polares em planos ortogonais, ou seja, as cores são localizadas em setores. Quanto mais distante do centro do cilindro, mais puras em matiz são as cores. O eixo da Saturação possui propriedades semelhantes ao eixo da Matiz e as cores mais próximas a borda do cilindro são mais saturadas. A representação do modelo HSI é ilustrado na Figura 3(b). Por último, mas não menos importante, destaca-se que é possível converter uma tonalidade de cor no espaço RGB para HSI e vice-versa, de acordo com a conveniência de cada representação. A Definição 2 apresenta uma conversão pixel-a-pixel entre os dois modelos.

**Definição 2.** [Conversão RGB para HSI] Um pixel  $P_i$  definido no espaço RGB pode ser representado em um espaço HSI por meio de uma transformação geométrica. Assumindo que o pixel  $P_i$  tenha valores normalizados, ou seja, que as coordenadas estejam no intervalo  $[0, 1]$ , as dimensões  $h_i$  (matiz),  $s_i$  (saturação) e  $v_i$  (intensidade) de  $P_i$  são dadas pela Equação (1):

$$h_i = \begin{cases} \cos^{-1} \left\{ \frac{\frac{1}{2} [(r_i - g_i) + (r_i - b_i)]}{[r_i - b_i]^2 + (r_i - b_i)(g_i - b_i)^{\frac{1}{2}}} \right\} & \text{se } b_i \leq g_i \\ 360 - \cos^{-1} \left\{ \frac{\frac{1}{2} [(r_i - g_i) + (r_i - b_i)]}{[r_i - b_i]^2 + (r_i - b_i)(g_i - b_i)^{\frac{1}{2}}} \right\} & \text{se } b_i > g_i \end{cases} \quad (1)$$

$$s_i = 1 - \frac{3}{(r_i + g_i + b_i)} [\min(r_i, g_i, b_i)]$$

$$v_i = \frac{1}{3} (r_i + g_i + b_i)$$

O modelo HSI de cores permite interpretar a luz visível, mas não é geometricamente “uniforme”, no sentido que uma mesma distância euclideana nesse espaço não representa a diferença proporcional perceptível entre os estímulos de cores. O CIE estabelece um outro modelo, o LAB, para representar cores em um espaço quase uniforme (CONNOLLY; FLEISS, 1997).

### 2.2.3 Modelo LAB

Este modelo de cores preza por gerar um espaço com alto nível de consistência das cores do diagrama CIE, independentemente do instrumento de projeção (JOHNSON; FAIRCHILD, 2003). O modelo se baseia na premissa de cores opostas com três pilares. O primeiro pilar apresenta, a luminosidade (L), enquanto os outros indicam cores diametralmente opostas (A e B) em um plano de coordenadas cromáticas. De forma mais detalhada, Zhang, Wandell et al. (1996) define as coordenadas LAB como:

- **L:** Representa a luminosidade, ou seja, descreve a intensidade da cor.

- A: Apresenta o valor dos eixos das cores opostas. Em um plano base (sem intensidade), essas cores são vermelha e verde, pois o eixo começa na cor vermelha e se torna verde conforme se aproxima do final.
- B: Corresponde as cores amarela e azul em um único eixo. Em um plano base (sem intensidade), essas cores são amarelo e azul.

A ilustração do modelo LAB é apresentado como uma sequência de planos na Figura 3(c). Ao contrário da conversão RGB para HSI, a conversão de um pixel do espaço RGB para o modelo LAB é uma sequência de duas transformações que incluem uma base intermediária, como na Definição 3.

**Definição 3.** [Conversão RGB para LAB] Um pixel  $P_i$  representado no espaço RGB unitário é representado no espaço LAB por intermédio de duas transformações: primeiro ao espaço XYZ e deste para o LAB, gerando as componentes  $L_i$ ,  $A_i$  e  $B_i$  de acordo com a Equação (2).

$$\begin{aligned}
 \begin{bmatrix} x_i \\ y_i \\ z_i \end{bmatrix} &= \begin{bmatrix} 0,4124 & 0,3576 & 0,1805 \\ 0,2126 & 0,7152 & 0,0722 \\ 0,0193 & 0,1192 & 0,9505 \end{bmatrix} \cdot \begin{bmatrix} r_i \\ g_i \\ b_i \end{bmatrix} \\
 L_i &= 116 * f\left(\frac{y_i}{100}\right) - 16, \\
 A_i &= 500 * f\left(\frac{x_i}{95,047} - \frac{y_i}{100}\right), \\
 B_i &= 200 * f\left(\frac{y_i}{100} - \frac{z_i}{108,883}\right), \\
 f(k) &= \begin{cases} \sqrt[3]{k}, & \text{se } k > (6/29)^3 \\ \frac{k}{3*(6/29)^2} + \frac{4}{29} & \text{caso contrário} \end{cases},
 \end{aligned} \tag{2}$$

## 2.3 Imagem Digital

Uma imagem digital  $I$  é um conjunto ordenado de pixels  $I = \{P_i \mid 0 \leq i < n\}$ , onde  $n$  é o número total de pixels. Caso um pixel  $P_i$  tenha as três dimensões RGB equivalentes em valor, i.e.,  $r_i = g_i = b_i$ , o pixel é dito *unidimensional*. Se todos os pixels  $P_i$  de uma imagem  $I$  forem unidimensionais, então a imagem é dita *monocromática*, apresenta aspecto visual de tons de cinza, e pode ser representado por apenas *um único valor* das quaisquer três dimensões do sistema RGB (SONKA; HLAVAC; BOYLE, 1993; JOHNSON; FAIRCHILD, 2003; CHANG; REID, 1996). Gonzalez e Woods (2008) definem as áreas de interesse para o processamento de imagens digitais em RGB ou monocromáticas em três níveis:

1. **Processo de baixo nível.** As operações primitivas do pré-processamentos de imagens visam realçá-las, aumentando o contraste, nitidez, brilho e ruídos. Para isso se empregam técnicas de transformações de tonalidade, filtragens espaciais e no domínio da frequência. Esse processo recebe uma imagem como entrada e também retorna uma única imagem.

2. **Processo de médio nível.** Caracterizado por tarefas de segmentação, o processo possui como objetivo descartar partes irrelevantes de uma imagem. Rotinas desse nível recebem uma imagem de entrada e geram uma ou mais imagens de saída.
3. **Processo de alto nível.** Buscam encontrar *significados* nas imagens, o que pode incluir técnicas de aprendizado de máquina para buscar determinados padrões, que podem ser representados por similaridades dentre e entre imagens.

Neste trabalho final de curso, abordaremos todos os três processos. Para o primeiro processo utilizaremos técnicas de filtragens. Já para o segundo processo, usaremos métodos de classificação para segmentar o fundo da imagem. Finalmente, no terceiro processo empregaremos algoritmos de agrupamento para unir padrões de tecidos em imagens de úlceras venosas.

### 2.3.1 Filtro da mediana

O filtro de mediana realiza a *normalização* de pixels em uma determinada vizinhança através da mediana. Os valores dos pixels vizinhos são ordenados e o valor do pixel consultado é substituído, como exemplificado na Figura 4.

143	110	146		143	110	146
105	249	208	⇒	105	208	208
229	240	239		229	240	239
(a)				(b)		

Figura 4 – Exemplo da aplicação do filtro da mediana para uma imagem em (a) e uma vizinhança de  $3 \times 3$  para o pixel unidimensional  $(1, 1) = 249$ . Tem-se que os vizinhos de (a) são: 143, 110, 146, 105, 208, 229, 240, 239 além do próprio 249. A mediana desses valores é 208. A imagem resultante (b) tem o pixel com os valores atualizados. As bordas não foram alteradas pois não há “encaixe” da janela de vizinhança de  $3 \times 3$ .

O filtro da mediana é um filtro estatístico que tem como objetivo descartar valores de *pixels* discrepantes em  $I$ . Portanto, o filtro altera os valores dos pixels unidimensionais baseados em uma janela de vizinhança (SUN; NEUVO, 1994). A extensão do filtro da mediana para pixels não unidimensionais é simples: basta se calcular a mediana para cada uma das três dimensões, sejam elas RGB, HSI ou LAB, em separado.

### 2.3.2 Método de Otsu

O método de Otsu é um algoritmo de limiarização que respeita a frequência dos valores de pixels de uma imagem. A abordagem é usualmente empregada para imagens monocromáticas, mas pode ser estendida para imagens *full-color*. A técnica depende da definição de um *threshold* (ponto de corte) ideal para transformar uma imagem monocromática em uma imagem de dois tons (binária). Essa definição é feita utilizando o histograma de tons de cinza da imagem monocromática (OTSU, 1979; ZHU et al., 2009).



Um histograma representa uma distribuição de frequência para um conjunto de valores (no caso da imagens monocromáticas, os valores são os tons de cinza) (KAPUR; SAHOO; WONG, 1985). Esses valores podem ser representados em um conjunto de inteiros delimitado no intervalo  $[1, 2, \dots, 2^b]$ , onde  $2^b$  representa a profundidade do valor do pixel unidimensional em bits. Para uma imagem  $I$ , a frequência acumulada no histograma é igual a quantidade  $n$  de pixels.

O histograma permite calcular o *threshold*  $\tau$  encarregado dividir (ou *binarizar*) os pixels em dois grupos:  $C_0$  e  $C_1$  (LI-SHENG et al., 2005). O grupo  $C_0$  será transformado em um único tom claro (0) e o grupo  $C_1$  será transformado em um único escuro (1). O cálculo da frequência de cada tonalidade  $t$  gera um vetor com a quantidade de pixels cujo valor unidimensional seja igual a  $t$ ,  $t \in [1, 2, \dots, 2^b]$ . A escolha do *threshold*  $\tau$  é feita iterativamente. Para cada iteração divide-se o histograma em duas partes, utilizando um valor candidato  $t$  para  $\tau$  no intervalo  $[1, 2, \dots, 2^b]$ . Calcula-se uma média  $\mu_1$  e uma variância  $\sigma_1^2$  para o histograma de pixels cujo valor de tonalidade seja menor ou igual a  $t$  e uma segunda média  $\mu_2$  e variância  $\sigma_2^2$  para o histograma de pixels cujo valor unidimensional seja maior que  $t$ . Se a variância entre os dois histogramas, calculada a partir das médias e variâncias 1 e 2, é a maior até o momento, então  $t$  é escolhido como o melhor candidato até essa iteração. Ao final das  $2^b$  iterações, o  $t$  de maior variância entre os dois histogramas é escolhido como o *threshold*  $\tau$ .

Seja uma imagem monocromática  $I$ , um histograma  $H$  construído para os valores  $t \in [1, 2, \dots, 2^b]$  e frequências de  $P_i \in I$ , o Algoritmo 1 resume o método de limiarização de Otsu.

---

**Entrada:** Imagem monocromática  $I$ , *threshold*  $\tau$

**Saída** : Imagem binária  $I'$

---

```

1  $I' \leftarrow \emptyset$ ;  $tMax \leftarrow -1$ ;  $varMax \leftarrow -1$ ;  $H \leftarrow \text{calcularHistograma}(I)$  ;
2 for  $t \in [1, 2, \dots, 2^b]$  do
3    $\mu_1 \leftarrow \text{media}(H \leq t)$ ;  $\sigma_1^2 \leftarrow \text{variancia}(\mu_1, H \leq t)$ ;
4    $\mu_2 \leftarrow \text{media}(H > t)$ ;  $\sigma_2^2 \leftarrow \text{variancia}(\mu_2, H > t)$ ;
5   if  $\text{varianciaEntreHistogramas}(H, \mu_1, \sigma_1^2, \mu_2, \sigma_2^2, t) > varMax$  then
6      $varMax \leftarrow \text{varianciaEntreHistogramas}(H, \mu_1, \sigma_1^2, \mu_2, \sigma_2^2, t)$ ;
7      $\tau \leftarrow t$  ;
8   end
9 end
10 for  $P_i \in I$  do
11   if  $r_i = g_i = b_i \leq \tau$  then
12      $P_i \leftarrow (1, 1, 1)$ 
13   else
14      $P_i \leftarrow (0, 0, 0)$ 
15   end
16    $I' \leftarrow I' \cup P_i$ ;
17 end
18 return  $I'$ ;

```

---

**Algoritmo 1:** Método de limiarização de Otsu.

### 2.3.3 Morfologia Matemática

As operações morfológicas contemplam a segunda fase de processamento de imagens com o objetivo de encontrar objetos específicos nas imagens. Esses objetos são figuras geométricas, denominadas de elementos estruturantes (SE) (ZHANG; CHEN; LIAO, 2011), que são uma pequena imagem a ser casada múltiplas vezes sobre a imagem processada como uma janela deslizante. O formato e os pixels de cada elemento estruturante é personalizado de acordo com aplicação ou contexto da imagem (GONZALEZ; WOODS, 2008). A Figura ?? ilustra exemplos de duas operações morfológicas em uma imagem binária. No exemplo, a imagem original (Figura ??(a)) tem o tamanho de  $486 \times 486$  pixels e o Elemento Estruturante SE é um quadrado completo de pixels brancos de tamanho  $11 \times 11$ .

**Dilatação.** A dilatação é um processo complementar a erosão, com o objetivo de expandir determinados objetos de uma imagem. Os processos de erosão e dilatação são semelhantes, pois combinam um elemento estruturante a uma imagem (SONKA; HLAVAC; BOYLE, 1993). Uma dilatação soma o elemento estruturante SE como uma janela sobre uma imagem binária  $I$  resultando em uma imagem  $I'$ , i.e.,  $I' = I \oplus SE$ . Na operação de soma, caso o pixel esteja contido na janela deslizante, então o valor do pixel se propaga para sua borda. Um exemplo de dilatação é ilustrado na Figura ??(b), onde as linhas foram dilatadas por um elemento quadrado de pixels brancos de tamanho  $11 \times 11$  e a imagem original está ilustrada na Figura ??(a).

**Erosão.** Seja uma imagem binária  $I$  e um elemento estruturante SE, ao se empregar a subtração de  $I$  por SE com o auxílio de uma janela deslizante sobre todos os pixels de  $i$  se obtém uma terceira imagem  $I'$ . A operação de subtração é denotada por  $\ominus$  e, portanto,  $I' = I \ominus SE$ . A erosão remove componentes que não estão contidos no intervalo de valores delimitado por SE. Visualmente, os valores restantes sofrem um “*afinamento*” em suas bordas. A Figura ??(c) ilustra a erosão da imagem original da Figura ??(a) por um elemento estruturante quadrado de pixels brancos de tamanho  $11 \times 11$ .

Ressalta-se que as operações morfológicas de dilatação e erosão são complementares, de maneira que aplicar a dilatação seguida por uma erosão com mesmo elemento estruturante gera a técnica conhecida como *abertura*. No entanto, caso a ordem da aplicação seja invertida o resultado da operação é diferente, o que gera a técnica conhecida como *fechamento* (SONKA; HLAVAC; BOYLE, 1993).

**Abertura.** O propósito desta operação morfológica é eliminar objetos de uma imagem e suavizar contornos dos objetivos restantes. O método de abertura sobre uma imagem binária  $I$  por SE, denotado por  $\circ$ , pode ser simplificado como  $I \circ SE = (I \ominus SE) \oplus SE$ .

**Fechamento.** A operação morfológica de fechamento busca restabelecer conexões entre objetos

sem modificar radicalmente o tamanho e a forma dos conjuntos iniciais (GIL; KIMMEL, 2002). O método de abertura sobre uma imagem binária  $I$  por SE, denotado por  $\bullet$ , pode ser simplificado como  $I \bullet SE = (I \oplus SE) \ominus SE$ .

#### 2.3.4 Superpixels

Superpixels são aglomerações de pixels em regiões de bordas visualmente bem definidas. Portanto, superpixels constituem uma estratégia de processamento de imagens de médio nível, onde, para cada imagem de entrada são obtidas diversas imagens de saída que, potencialmente, representam objetos individuais. A Definição 4 formaliza o conceito de superpixel.

**Definição 4.** *[Superpixel] Um superpixel  $S$  corresponde a um conjunto ordenado de pixels  $S \subseteq I$  definido com  $S = \{P_j \mid 0 \leq j < m\}$ , onde  $m$  ( $m \leq n$ ) é o número de pixels dentro do superpixel  $S$ . O valor médio, ou extraído, de um superpixel é dado por um tupla  $\bar{P}_S, \bar{P}_S = \langle \mu(s_1), \mu(s_2), \mu(s_3) \rangle$ , onde  $\mu(k) = \sum_{j=0}^{m-1} k_j / m$ , representando a média de valores dos pixels de  $S$  em um espaço de cor de três dimensões arbitrários, i.e., RGB, HSI ou LAB. O conjunto de superpixels extraídos de uma imagem  $I$  é denotado por  $S$ .*

Um algoritmo de geração de superpixels inicia como uma estrutura rígida de *grade* de pixels que se moldam as bordas de acordo com a semelhança entre os pixels. Esses algoritmos podem ser baseados em soluções derivadas de grafos ou cálculo de gradiente sobre um modelo de cor (FELZENSZWALB; HUTTENLOCHER, 2004; VEDALDI; SOATTO, 2008). De forma geral, esses métodos são funções  $g(I, K_p) = \{S_j \mid 0 \leq j < K_p\}$  que usam uma imagem  $I$  e geram  $K_p$  superpixels disjuntos e não-vazios  $S_j$ ,  $S_j \subset I$ . A pesquisa comparativa empírica de Achanta et al. (2012) avalia diversos métodos de geração de superpixels, incluindo:

- TP09: A técnica *Turbopixel* dilata progressivamente um conjunto de sementes usando o fluxo geométrico de gradientes da imagem.
- NC05: O método particiona, recursivamente, um grafo de todos os pixels da imagem usando pistas de contorno e textura, minimizando globalmente uma função de custo definida nas bordas nos limites da partição.
- GCa10 e GCb10: O agrupamento dos superpixels é feito pela mescla de pixels da imagem, que são sobrepostos de forma que cada pixel pertença a apenas uma região. A diferença entre as duas variantes (GCa10 e GCb10) é que o GCa10 gera superpixels mais compactos por intensidade de cor.
- QS09: A técnica *QuickShift* escolhe um pixel central para o agrupamento e move os pixels adjacentes recursivamente para aumentar a densidade de Parzen.
- GS04: Realiza um agrupamento aglomerativo de pixels como nós em um grafo, de modo que cada superpixel pode ser visto como a árvore geradora mínima dos pixels envolvidos.




Figura 5 – Exemplo de superpixels gerados pelo método SLIC. Adaptado de Achanta et al. (2012).

- Squares: Gera um *grid* uniforme de superpixels.
- GSLIC: Variação do método SLIC (descrito na sequência), tendo a medida de distância euclidiana alterada para distância geodésica, que garante conectividade.
- ASLIC: Variação do método SLIC (descrito na sequência), que adota a medida de distância euclidiana *normalizada* de acordo com o espaço de cores.

**SLIC.** O método SLIC se destaca graças a sua eficiência computacional e escalabilidade. Isso se dá porque o SLIC otimiza o cálculo de distância entre os pixels dentro do superpixel e restringe a região de busca proporcionalmente ao tamanho do superpixel.

A implementação do SLIC requer apenas um único parâmetro para seu funcionamento: o número  $k$  final de superpixels *desejado*. Tendo por base o número  $k$ , o SLIC inicia a etapa de armazenamento dos pixels em grupos, começando com  $k$  centros de grupos descritos no espaço LAB e escolhidos como os pontos centrais de um *grade* regular e equi-espçada sobre a figura. A cada iteração, os centróides dos grupos são movidos para os locais cuja posição do gradiente de cor LAB seja a mais baixa de todo o superpixel. Assim, cada pixel é atribuído ao centróide mais próximo no espaço LAB, sendo que apenas centróides que estejam dentro de um limiar de distância de localização na imagem são considerados como candidatos. Essa limiarização é fundamental para melhorar a velocidade de processamento do algoritmo, em virtude de restringir um limite para busca por centróides candidatos. O limiar é calculado dinamicamente em função da área de cada superpixel e da totalidade da área da imagem.

Quando todos os pixel tiverem sido associados aos seus respectivos grupos, os centróides são atualizados novamente e um erro residual é calculado considerando-se as posições atuais e anteriores dos centróides no espaço LAB. O processo de atribuição e atualização de centróides se repete até a convergência do erro residual. Por último, o SLIC faz um pós-processamento que impõe conectividade para os superpixels ao unir os pixels separados em grupos pequenos aos superpixels próximos (ACHANTA et al., 2012).

## 2.4 Aprendizado de Máquina

A finalidade do aprendizado de máquina (AM) é encontrar padrões através da análise dos dados via algoritmos de tomada de decisão que não são explicitamente programados como um programa tradicional (SULLIVAN, 2017). De fato, diversos autores buscam *separar* a programação tradicional e AM, como Sullivan (2017):

- Programação tradicional: Recebe dados que serão processados de forma determinística ou com um (ou mais) fluxo de ações pré-definido pelo programador. Em suma, pode ser descrito como um programa que possui entrada e saída.
- Aprendizado de Máquina: Algoritmo genérico, que se torna especializado na tomada de decisão com base em um conjunto de dados previamente fornecido para sua especialização. Ao contrário da programação tradicional, o algoritmo de AM recebe diversos dados e tenta encontrar padrões relevantes para o conjunto e não, necessariamente, para um domínio genérico. O comportamento do processamento é determinado em boa parte pelos dados e não apenas por um fluxo de programação. A Figura 6 mostra um algoritmo de AM, com viés de aprendizado linear, que encontrou uma fronteira de decisão para um conjunto de dados de duas classes.

Em específico, AM apresenta dois paradigmas fundamentais para a detecção de padrões em conjuntos de dados, a saber: supervisionado e não supervisionado (BONACCORSO, 2018). Esses paradigmas podem ser melhor detalhados como:

- Supervisionado: Aprendizado indutivo, onde a análise é feita sobre coleções de dados rotuladas. O algoritmo de aprendizado terá que realizar classificação. O aprendizado supervisionado apresenta duas fases: treinamento e teste. A fase de treinamento consiste em detectar padrões correlacionados aos rótulos, enquanto a fase de teste usa esses padrões para rotular novos dados desconhecidos que são apresentados para classificação. As métricas de qualidade obtidas pelos diferentes algoritmos dependem do resultado do classificador em acertar os rótulos.
- Não supervisionado: Possui o objetivo de identificar propriedades de dados que não apresentam rótulos. Rotular conjuntos de dados com alta precisão, muitas vezes é uma tarefa dispendiosa ou infactível, razão pela qual identificar padrões sem auxílio de classificação é tão importante. Algoritmos não supervisionados geralmente demandam conjuntos de maior *cardinalidade* (número de entradas, ou *instâncias*, do conjunto de dados) que os supervisionados (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

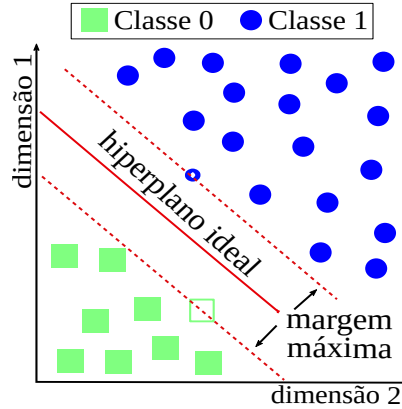


Figura 6 – Exemplo de fronteira de decisão para duas classes. Todos os objetos que estiverem acima da linha serão classificados como Classe 0 e os abaixo da linha como Classe 1. Adaptado de Wang (2005).

#### 2.4.1 Classificação de Dados

Um classificador busca rotular dados a partir de um viés de aprendizado e um conjunto rotulado de exemplos. No caso desse trabalho, os dados são pedaços das imagens – superpixels, ou suas unidades atômicas – pixels, que podem ser rotulados por um especialista do domínio, *i.e.*, dermatologista, ou por um biomarcador, *i.e.*, análise de biópsia em laboratório. A Definição 5 formaliza o conceito de um classificador como uma função cujo comportamento depende do conjunto de dados de entrada desse tipo.

**Definição 5.** [Classificador] Um classificador  $\phi$  é uma função  $\phi : \{\mathcal{P}, T\} \rightarrow L$ , onde  $L$  é um conjunto discreto e disjunto de rótulos,  $\mathcal{P}$  é o domínio dos pixels, *i.e.*, RGB, HSI ou LAB, e  $T$  é o conjunto de treinamento que condiciona o comportamento de  $\phi$ . Em particular, dado o domínio  $\mathcal{P}$ ,  $T$  representa um conjunto finito e não-vazio de pixels rotulados, *i.e.*,  $T = \{\langle P_i, l_j \rangle \mid L = \cup_j l_j\}$ , e o algoritmo de aprendizado do classificador é um método enviesado que define o comportamento de  $\phi$  a partir de  $T$ .

Diferentes vieses podem ser usados no algoritmo de aprendizagem para prever rótulos, sendo que a literatura costuma dividi-los em categorias (FACELI; CARVALHO; SOUTO, 2008). As categorias mais conhecidas são: simbólica, conexionista, bayesiana e por exemplos (DOMINGOS, 2015; BRADLEY, 1997), detalhadas na sequência.

- **Simbólica:** Identifica padrões por meio de estruturas simbólicas, *i.e.*, árvores. Algoritmos desse paradigma incluem Decision Tree (DT), RandomForest (RF) e RandomTree (RT).
- **Conexionista:** Inspirado na estrutura de aprendizagem cerebral, que é descrita por meio de ajustes das conexões entre os neurônios. Exemplos de algoritmos desse paradigma incluem as redes neurais artificiais Perceptron e Multi-Layer Perceptron (MLP).

- Bayesiana: Busca identificar padrões por intermédio da probabilidade de ocorrência de uma classe conhecida. Tendo como exemplos de algoritmos desse paradigma incluem Naïve-Bayes (NB) e Bayes-Net (BN).
- Por exemplos: Possui o intuito de detectar padrões baseados em instâncias conhecidas. Portanto, se baseia em calcular a semelhança de uma instância para outra. Exemplos de algoritmos desse paradigma são os  $k$ -Vizinhos mais próximos (kNN) e Máquina de Vetores de Suporte (SVM).

Para se medir a qualidade de um classificador utiliza-se um outro conjunto de teste rotulado (diferente daquele empregado em seu treinamento) e solicita-se a classificação de cada instância desse segundo conjunto de forma individual. Os acertos e os erros do classificador são anotados em uma matriz, denominada *matriz de confusão*. A Figura 7 apresenta um exemplo de matriz de confusão para um conjunto de dados que possui apenas dois rótulos  $L = \{\text{Positivo}, \text{Negativo}\}$ . A matriz ilustra os índices de acerto e erro de um classificador, detalhando o que foi classificado como Positivo e realmente o é, denominado de Verdadeiro Positivo (TP), e o Negativo que foi rotulado como Positivo, denominado Falso Positivo (FP). Além disso, a matriz indica os dados Positivos classificados como Negativos, os chamados Falso Negativos (FN), e as instâncias Negativas realmente rotuladas como tal, os Verdadeiros Negativos (TN) (TOWNSEND, 1971; FACELI; CARVALHO; SOUTO, 2008; AGGARWAL, 2015).

	Real Positivo	Real Negativo
Predito Positivo	TP	FP
Predito Negativo	FN	TN

Figura 7 – Exemplo de matriz de confusão para duas classes  $L = \{\text{Positivo}, \text{Negativo}\}$ .

Por intermédio da matriz de confusão pode-se obter diversos índices e métricas de qualidade que avaliam o desempenho dos classificadores (CONGALTON; GREEN, 2019; POWERS, 2011). Exemplos de métricas que usaremos na validação do trabalho proposta incluem:

- Revocação ou Sensibilidade: Mede a proporção de verdadeiros positivos (TP) com relação a todos os positivos. A Equação (3) detalha essa métrica.

$$\text{Revocação} = \text{Sensibilidade} = \frac{TP}{TP + FN} \quad (3)$$

- Precisão ou Confiança: Denota a proporção de verdadeiros positivos (TP) considerando todas as instâncias rotuladas como positivas. A Equação (4) calcula essa métrica.

$$\text{Precisão} = \text{Confiança} = \frac{TP}{TP + FP} \quad (4)$$

- Especificidade ou Seletividade: Mede a proporção de verdadeiros negativos (TN) com relação às instâncias preditas negativas. A Equação (5) apresenta a *Especificidade*.

$$Especificidade = Seletividade = \frac{TN}{TN + FP} \quad (5)$$

- Acurácia: Mostra o acerto global do classificador como uma proporção de resultados verdadeiros entre o número total de casos examinados. A Equação (6) apresenta essa métrica.

$$Acurácia = \frac{TN + TP}{TN + TP + FN + FP} \quad (6)$$

- F-Measure: Combina as medidas de *Precisão* e *Revocação* em uma média harmônica, focada nos exemplos positivos e nas previsões corretas. A Equação 7 detalha essa métrica.

$$F-Measure = 2 * \left( \frac{Precisão * Revocação}{Precisão + Revocação} \right) \quad (7)$$

- MSE e MAE: Quantificam os acertos das previsões. O *Mean Squared Error* (MSE) usa o erro quadrático médio e o *Mean Absolute Error* (MAE) usa a diferença absoluta entre a classe real e a predita, tal qual nas Equações (8) e (9), que usam  $\eta$  como o tamanho do conjunto de dados de teste.

$$MSE = \frac{1}{\eta} \sum_{i=1}^{\eta} (predita - real)^2 \quad (8)$$

$$MAE = \frac{1}{\eta} \sum_{i=1}^{\eta} |predita - real| \quad (9)$$

- Coeficiente Cohen-Kappa: Avalia os níveis de concordância entre dois conjuntos de rótulos, tal qual expresso na Equação 10.

$$\kappa = \left( \frac{\lambda_o - \lambda_e}{1 - \lambda_e} \right) = 1 - \left( \frac{1 - \lambda_o}{1 - \lambda_e} \right), \quad (10)$$

onde  $\lambda_o$  é a taxa de aceitação relativa e  $\lambda_e$  simboliza a taxa hipotética de aceitação. Explicitamente,  $\lambda_o = (\frac{TP+TN}{\eta})$  e  $\lambda_e = (\frac{TP+FP}{\eta} \cdot \frac{TP+FN}{\eta}) + (\frac{FN+TN}{\eta} \cdot \frac{FP+TN}{\eta})$ ,  $\eta$  sendo o tamanho do conjunto de testes.

O Coeficiente de Cohen-Kappa permite interpretar a qualidade de um classificador em termos semânticos (SIM; WRIGHT, 2005). A Figura 8 apresenta o intervalo de valores do Coeficiente de Cohen-Kappa associado ao nível de concordância semântica.

Por último, Provost et al. (1998) argumenta que usar simplesmente um único valor de qualidade pode ser enganoso, recomendando também aplicar outras formas de avaliações, como a



Coeficiente de Kappa-Cohen	Nível de Concordância
0	Pobre
0 – 0,20	Leve
0,21 – 0,40	Considerável
0,41 – 0,60	Moderada
0,61 – 0,80	Substancial
0,81 – 1	Excelente

Figura 8 – Nível de concordância do Coeficiente de Cohen–Kappa

curva de Característica do Operador do Receptor (ROC). Essa curva ilustra como o número de exemplos positivos corretamente classificados varia de acordo com o número de exemplos negativos classificados incorretamente (PROVOST et al., 1998). A curva ROC utiliza as métricas de *Revocação* e a *Especificidade* para sua elaboração, onde cada ponto na curva ROC representa um par de *Revocação* e *Especificidade*. Devido a essas diversas perspectivas de qualidade, nesse trabalho serão utilizados mais uma métrica de avaliação de classificação, de maneira, a evitar qualquer tipo de visão excessivamente otimista do desempenho de um classificador.

#### 2.4.2 Redes Neurais Artificiais

A proposta do Perceptron (MCCULLOCH; PITTS, 1943) estabelece um modelo linear de classificação que recebe várias entradas e as processa por uma função linear. No caso de um pixel  $P_i$ , as entradas são o valor da pixel em cada uma das dimensões que o descreve, *e.g.*,  $r_i$ ,  $g_i$  e  $b_i$ . Uma unidade que realiza a soma ponderada sobre cada entrada com pesos iniciais aleatórios é denominada *neurônio* Perception. Após o processamento por um neurônio há uma saída de valor real que pode ser convertida em binário, se conveniente ao domínio. Caso o valor de saída não for o esperado, o neurônio pode ser *treinado* ao se acrescentar ou diminuir o peso que ele atribui a cada entrada (MCCULLOCH; PITTS, 1943; ROSENBLATT, 1958).

Redes neurais artificiais são evoluções/variações do Perceptron e possuem propriedades e componentes que as diferenciam entre si, tais como número de neurônios, sinapses, número de camadas, função de ativação e topologia. Esses aspectos podem ser detalhados como:

- Neurônio: Unidade que desempenha o processamento unitário da rede. Recebe várias entradas (dimensões) simultaneamente para cada instância, podendo transformá-las de acordo com uma função de ativação, e as associa com pesos, inicialmente aleatórios. Como resultado, obtém-se um único valor de saída, que pode ser usado como entrada para outros neurônios, caso exista uma ligação (sinapse) entre eles (ZHANG; PATUWO; HU, 1998; AGGARWAL, 2015).
- Sinapse: Responsável por interligar neurônios e propagar entradas e saídas. As sinapses também são responsável de interligar as camadas da rede.

- Camadas: Incluem um conjunto de neurônios e sinapses em uma determinada posição na topologia da rede, ou seja, uma camada é uma pequena rede neural artificial com neurônios paralelos. Algumas camadas possuem uma nomenclatura especial, como a (i) camada de entrada, cuja quantidade de neurônios está, geralmente, associada ao número de dimensões que descrevem as instâncias, (ii) camada de saída, onde a quantidade de neurônios é geralmente, associado ao número de possíveis rótulos, e (iii) camadas ocultas, que estão entre a camada de entrada e a camada de saída (HECHT-NIELSEN, 1988; ZHANG; PATUWO; HU, 1998).
- Função de ativação: Define a influência da dimensão na combinação linear com o peso. Um exemplo de função de ativação é sigmóide logística, que fornece resultados no intervalo  $[0, 1]$  (LIPPMANN, 1987; JAIN; MAO; MOHIUDDIN, 1996).
- Topologia: É a organização dos elementos da rede e a forma como os neurônios e camadas estão ligados. A Figura 9 ilustra um exemplo de topologia da uma rede MLP totalmente conectada. Toda topologia organiza a quantidade de camadas e a quantidade de neurônio, além de indicar quais desses neurônios se ligam a outros. Além disso, a topologia também indica qual o algoritmo de treinamento da rede, *i.e.*, a estratégia a ser usada para ajustar os pesos inicialmente aleatórios (KWOK; YEUNG, 1997; RUSSELL; NORVIG, 2016).




Figura 9 – Topologia de uma MLP totalmente conectada. (a) Camada de entrada. (b) Camada oculta. (c) Camada de saída.

**Treinamento.** O treinamento de uma rede neural artificial é o ajuste dos pesos de seus neurônios. Os dados (sem rótulos) são inseridos na camada de entrada e transmitidos para as camadas ocultas por intermédio das sinapses até a camada de saída. O valor da saída é comparado com o rótulo real e, em caso de divergência, todos os pesos da rede são atualizados. Os pesos começam com valores aleatórios entre  $[0, 1]$  e podem ser aumentados ou diminuídos a cada exemplo.

O ajuste dos pesos depende da conexão entre os neurônios na topologia da rede, que podem resultar em ajustes *feedforward* e *backpropagation*. A Figura 10 apresenta as duas diferentes conexões topológicas, sendo que a conexão *backpropagation* inclui retroalimentação e é a mais utilizada (FACELI; CARVALHO; SOUTO, 2008).

Dois métodos podem ser usados para ajuste de pesos com conexão com *backpropagation*: o *Resilient Propagation* (RPROP) e a abordagem de Levenberg-Marquardt (LM) (RIEDMIL-




Figura 10 – Conexão *feedforward* e *backpropagation*.

LER, 2005; CORTEZ; ROCHA; NEVES, 2002).

**Resilient-propagation – RPROP.** O método RPROP traz uma solução para as funções de ativação sigmóide ou tangente hiperbólica, que podem provocar a ocorrência da saturação da saída dos neurônios e gerar valores próximos de zero, o que influencia a velocidade de convergência da rede neural artificial. Em particular, a solução RPROP de Riedmiller (2005) propõe atualizar os pesos considerando a variação do sinal do gradiente do erro ao invés das magnitudes do gradiente em si.

**Levenberg-Marquardt – LM.** O método de Levenberg-Marquardt é uma aproximação do método de Newton e é uma alternativa para o custo computacional elevado da convergência do RPROP. O algoritmo implementa um gradiente de segunda ordem, baseado no método dos mínimos quadrados para modelos não lineares (SURATGAR; TAVAKOLI; HOSEINABADI, 2005; YU; WILAMOWSKI, 2011), o que permite treinar a rede em tempo menor que o do RPROP e com a mesma qualidade de resultado para topologias não muito grandes.

#### 2.4.3 Agrupamento de Dados

Algoritmos de agrupamento de dados permitem analisar conjunto de dados não-rotulados (JAIN; DUBES, 1988). Esses métodos tem por objetivo dividir os dados em *clusters* (grupos) de acordo com suas características. Existem diversas abordagens e perspectivas de agrupamento (FACELI; CARVALHO; SOUTO, 2008), mas o foco desse trabalho é baseado em algoritmos de agrupamento particionais baseados em medidas de similaridade (AGGARWAL, 2015; HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Nesse contexto, os dados são superpixels (ou pixels), identificados por três dimensões de acordo com o modelo de cores adotado e o algoritmo de agrupamento funciona como uma função dada pela Definição 6.

**Definição 6.** [Agrupamento Particional] Um método de agrupamento particional é uma função  $\theta$  que divide as entradas em um conjunto disjunto de grupos. Dado um conjunto de superpixels  $S$  e um conjunto de grupos  $C$ , o método de agrupamento  $\theta : S \rightarrow C$  coloca cada superpixel  $S \in S$  em apenas um único grupo  $C \in C$  tal que  $\cup_{C_i \in C} C_i = S$  e  $\cap_{C_i \in C} C_i = \emptyset$ .

A base para os algoritmos particionais desse tipo é medir a *semelhança* entre dois elementos de dados, de acordo com sua representação multidimensional. Uma modelagem eficiente para esse problema é a representação de similaridade por distâncias, por meio da Teoria de Espaços

Métricos (HETLAND, 2009). Uma função de distância é uma métrica de similaridade, com a intuição semântica de quanto maior a distância entre dois elementos de dados, mais dissimilares eles são. A Definição 7 formaliza o conceito de função de distância métrica e a Definição 8 apresenta a família Minkowski de distâncias que serão usadas no restante desse trabalho.

**Definição 7.** *[Função de distância métrica] Uma função de distância métrica  $\delta$  é uma função  $\delta : \mathbb{M} \times \mathbb{M} \rightarrow \mathbb{R}_+$  que mede a semelhança entre dois pontos em  $\mathbb{M}$ , i.e., coordenadas LAB. Para quaisquer  $m_1, m_2, m_3 \in \mathbb{M}$ ,  $\delta$  satisfaz as seguintes propriedades: (i) simetria, (ii) não-negatividade e (iii) desigualdade triangular.*

**Definição 8.** *[Família Minkowski de funções –  $L_p$ ] Dados dois elementos de dados  $x$  e  $y$  descritos em um espaço  $d$ -dimensional, i.e.,  $x, y \in \mathbb{R}^d$ , uma função de Minkowski  $L_p$  é uma função de distância métrica que calcula a similaridade entre  $x$  e  $y$  de acordo com a Equação 11.*

$$L_p = \left( \sum_{i=1}^d (|x_i - y_i|^p) \right)^{\frac{1}{p}}, \quad (11)$$

para qualquer  $p, p > 0$ . As funções de distâncias mais conhecidas de Minkowski são as funções  $L_1$  (City-Block),  $L_2$  (Euclideana) e  $L_\infty$  (Chebyshev).

Além das funções de Minkowski, outras métricas também são comumente empregadas como as funções Canberra e BrayCurtis (HETLAND, 2009; BLANCO et al., 2016). Ainda considerando dois elementos de dados  $x$  e  $y$  descritos em um espaço  $d$ -dimensional, a distância de Canberra calcula a similaridade entre eles como expresso na Equação 12, enquanto a distância de Bray-Curtis usa a fórmula definida na Equação 13.

$$\delta(x, y) = \sum_{i=1}^d \frac{|x_i - y_i|}{|x_i| + |y_i|} \quad (12)$$

$$\delta(x, y) = 1 - \frac{\sum_{i=1}^d |x_i - y_i|}{\sum_{i=1}^d x_i + \sum_{i=1}^d y_i} \quad (13)$$

De forma geral, um algoritmo de agrupamento particional irá colocar as instâncias mais similares em um mesmo grupo e tentará afastar os grupos. Assim como para classificadores, diversas medidas de qualidade podem ser empregadas para medir a qualidade dos agrupamentos.

**Medidas avaliativas.** Ao contrário da matriz de confusão para classificadores, a qualidade dos métodos de agrupamento é mais subjetiva e depende, por vezes, da interferência humana (especialista do domínio). De forma geral, três medidas de qualidade podem ser usadas para essa finalidade:

- Número de grupos: Quando existe a noção de quantos grupos são esperados, essa medida pode auxiliar a indicar se a quantidade de grupos formados é adequado e se cada grupo constitui uma possível classe de dados.

- Índices internos: Verificam a qualidade da partição obtida sem considerar informações externas como um valor real. O coeficiente de silhueta é um exemplo dessa medida.
- Relativos: Comparam dois grupos, utilizando de medidas orientadas a similaridade, como coesão intra grupos e separação inter grupos.

#### 2.4.4 DBSCAN

O método DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) é baseado na densidade de elementos por espaço, onde as instâncias do conjunto de dados são agrupadas por similaridade. Seguindo essa premissa, o algoritmo se destaca na detecção de grupos de formato arbitrário (ESTER et al., 1996; MUMTAZ; DURAI SWAMY, 2010). As propriedades de densidade são obtidas em função da distância máxima de similaridade, o que gera propriedades interessantes para espaços multidimensionais, como os exemplos na Figura 11. Entretanto, o método requer parâmetros externos para funcionar: a distância máxima de similaridade  $\xi$  e o número mínimo de pontos aceitáveis para um grupo (TAN et al., 2007). De forma geral, uma partição gerada pelo DBSCAN tem as seguintes propriedades:

1. Todos os pontos dentro do *cluster* são mutuamente densamente conexos;
2. Se um ponto é alcançável por densidade por algum ponto dentro de um *cluster*, então ele também deve fazer parte do *cluster*<sup>2</sup>.

<sup>2</sup> Empates são quebrados arbitrariamente.

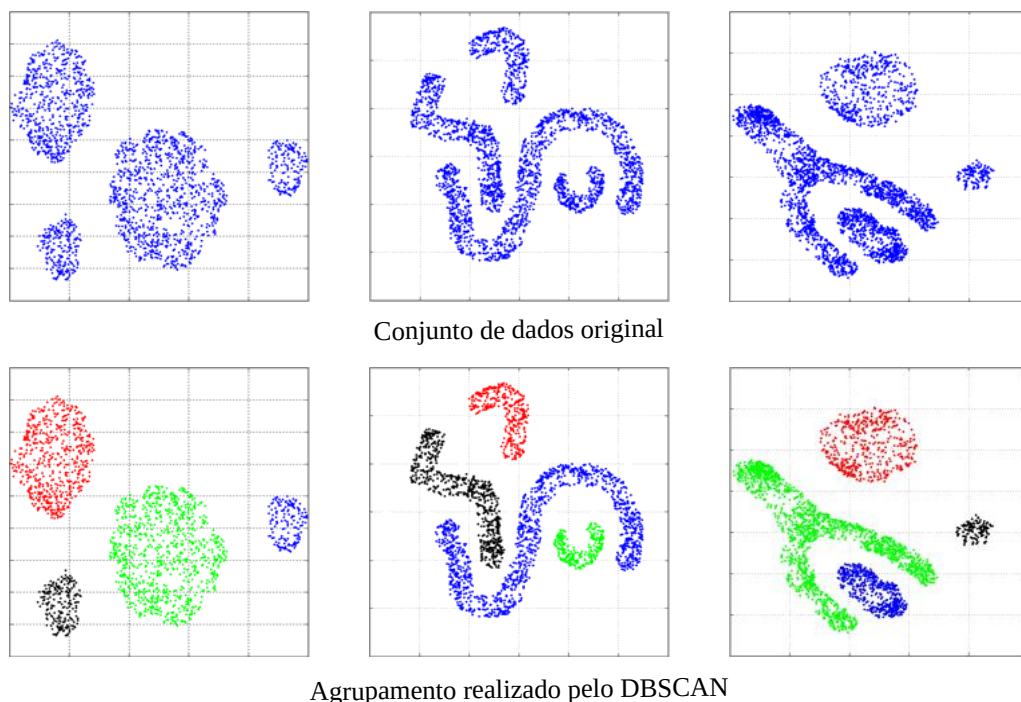


Figura 11 – Exemplos de formatos de agrupamento gerados pelo DBSCAN. Adaptado de Mumtaz e Duraiswamy (2010).

A Figura 12 ilustra as iterações do algoritmo DBSCAN para a função de distância  $\delta = L_2$ , distância máxima  $\xi = 2$  e um número mínimo de pontos por *cluster* igual a dois. A Tabela 1 apresenta os pontos bidimensionais para demonstrar o método do DBSCAN, enquanto a Figura 12(a) mostra os pontos bidimensionais em um gráfico.

Tabela 1 – Conjunto demonstrativo para o método do DBSCAN

Coordenada cartesiana			Coordenada cartesiana		
Elementos	X	Y	Elementos	X	Y
A	0,05	0,40	K	4,27	9,37
B	0,18	1,29	L	4,45	3,35
C	0,99	8,80	M	4,91	7,82
D	1,15	2,27	N	5,80	8,70
E	1,45	9,32	O	5,74	7,47
F	1,85	0,29	P	5,93	6,30
G	3,38	7,39	Q	6,28	7,00
H	3,76	8,28	R	7,15	4,60
I	3,92	3,46	S	7,00	3,00
J	4,00	9,54	T	7,36	0,00

O algoritmo DBSCAN pode ser dividido em sete etapas, exemplificadas na sequência para o conjunto de dados bidimensional da Figura 12(a).

1. O método depende da similaridade entre os elementos do conjunto e, portanto, da construção de uma matriz de distâncias. A Tabela 2 mostra a matriz de distâncias para o conjunto de dados da Tabela 1. Por meio da matriz de distâncias, classificam-se os elementos de dados de acordo com a distância entre as instâncias e seu número de vizinhos.
2. Elementos de dados podem receber um dos seguintes rótulo: *Core*, *Border* e *Noise*. Esses rótulos são atribuídos de acordo com a seguinte regra: (i) se função de distância entre o elemento e seus vizinho é igual ou menor que o limite  $\xi$  e a quantidade de vizinhos é maior ou igual ao número mínimo de pontos, então o elemento é rotulado como *Core*; (ii) caso a quantidade de vizinhos dentro de um limiar de distância  $\xi$  for maior ou igual a 1 e menor do que número mínimo de pontos, então o elemento é rotulado como *Border*, e, finalmente, (iii) se o elemento não for *Core* nem *Border*, então será rotulado como *Noise*. No exemplo da Figura 12(a), são gerados os rótulos associados aos elementos para um limiar de distância  $\xi = 2$  e um número mínimo de vizinhos igual a dois, de acordo com Tabela 3. A Figura 12(b) apresenta os elementos rotulados entre *Core*, *Border* e *Noise*.
3. Após a classificação dos elementos, agrupa-se os elementos *Core*. O objetivo é construir arestas interligando todos os elementos vizinhos que sejam *Core*. A Figura 12(c) mostra as arestas para os elementos rotulados com *Core* na Figura 12(b) de acordo com os vizinhos descritos na Tabela 3 que foram obtidos à partir da matriz de distâncias (Tabela 2), limiar  $\xi = 2$  e número de vizinhos igual a dois.

Tabela 2 – Matriz de distâncias para o DBSCAN

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
A	0,00	0,90	8,45	2,17	9,03	1,80	7,74	8,71	4,93	9,96	9,91	5,30	8,87	10,10	9,08	8,33	9,08	8,25	7,42	7,32
B	-	0,00	7,55	1,38	8,13	1,95	6,89	7,85	4,32	9,09	9,06	4,74	8,06	9,30	8,31	7,63	8,36	7,72	7,03	7,30
C	-	-	0,00	6,53	0,69	8,55	2,77	2,82	6,09	3,10	3,33	6,46	4,04	4,81	4,93	5,54	5,59	7,46	8,35	10,86
D	-	-	-	0,00	7,06	2,10	5,58	6,55	3,01	7,81	7,76	3,47	6,70	7,94	6,94	6,25	6,98	6,44	5,90	6,61
E	-	-	-	-	0,00	9,04	2,73	2,53	6,36	2,56	2,82	6,68	3,77	4,39	4,67	5,40	5,36	7,40	8,41	11,04
F	-	-	-	-	-	0,00	7,26	8,22	3,79	9,50	9,40	4,02	8,13	9,29	8,17	7,26	8,04	6,83	5,82	5,52
G	-	-	-	-	-	-	0,00	0,97	3,97	2,24	2,17	4,18	1,59	2,75	2,36	2,77	2,93	4,69	5,69	8,39
H	-	-	-	-	-	-	-	0,00	4,82	1,28	1,20	4,98	1,24	2,08	2,14	2,94	2,83	5,00	6,19	9,03
I	-	-	-	-	-	-	-	-	0,00	6,08	5,92	0,54	4,47	5,57	4,40	3,48	4,25	3,43	3,11	4,88
J	-	-	-	-	-	-	-	-	-	0,00	0,32	6,21	1,95	1,99	2,70	3,77	3,41	5,86	7,20	10,11
K	-	-	-	-	-	-	-	-	-	-	0,00	6,02	1,68	1,67	2,40	3,49	3,11	5,57	6,93	9,87
L	-	-	-	-	-	-	-	-	-	-	-	0,00	4,49	5,52	4,32	3,30	4,08	2,98	2,57	4,44
M	-	-	-	-	-	-	-	-	-	-	-	-	0,00	1,25	0,90	1,83	1,60	3,92	5,25	8,19
N	-	-	-	-	-	-	-	-	-	-	-	-	-	0,00	1,23	2,40	1,77	4,32	5,82	8,84
O	-	-	-	-	-	-	-	-	-	-	-	-	-	-	0,00	1,19	0,72	3,20	4,64	7,64
P	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	0,00	0,78	2,09	3,47	6,46
Q	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	0,00	2,55	4,06	7,08
R	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	0,00	1,61	4,60
S	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	0,00	3,02
T	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	0,00

Tabela 3 – Síntese da matriz de distância

	Nº Viz.	Vizinhos	Rótulo						Nº Viz.	Vizinhos	Rótulo	
A	2	B,F	Core						K	2	H,J	Core
B	2	A,F	Core						L	1	I	Border
C	1	E	Border						M	3	G,N,O	Core
D	1	B	Border						N	2	M,O	Core
E	1	C	Border						O	4	M,N,P,Q	Core
F	2	A,B	Core						P	2	O,Q	Core
G	2	H,M	Core						Q	2	O,P	Core
H	3	G,J,K	Core						R	1	S	Border
I	1	L	Border						S	1	R	Border
J	2	H,K	Core						T	0	-	Noise

- O próximo passo é gerar componentes os conexos de elementos rotulados como *Core*, sendo uma das possibilidades para a geração desses componentes conexos o uso de árvores geradoras mínimas. A Figura 12(d) mostra os componentes conexos produzidos para a Figura 12(c).
- Após o agrupamento dos elementos rotulados como *Core*, são analisados os elementos rotulados como *Border*, que são associados ao seu vizinho mais próximo como exemplificado na Figura 12(e).
- O próximo passo é agrupar os elementos rotulados como *Noise*. Diversas políticas podem ser empregadas nesse ponto, tais como atribuir cada elemento “*Noise*” a um grupo ou agrupá-los todos em um único grupo. Nesse trabalho, considera-se a primeira política. A Figura 12(e) mostra os elementos *Noise* da Figura 12(b) como grupos unitários.
- Finalmente, o DBSCAN realiza a substituição dos rótulos iniciais por rótulos dos grupos, onde todos os elementos conectados pelo mesmo caminho serão agrupados em um mesmo




Figura 12 – Exemplo do algoritmo DBSCAN. (a) Visualização do conjunto dos dados do exemplo. (b) Agrupamento e classificação dos elementos de acordo com número de vizinhos e distância. (c) Construção de arestas entre os elementos rotulado como *Core*. (d) Determinação do componente dos elementos *Core*. (e) Agrupamento dos elementos *Border* e *Noise* (f) Resultado final do agrupamento.



*cluster* e as arestas descartadas. O resultado final do método DBSCAN para o exemplo da Figura 12(a) é mostrado na Figura 12(f).

## 2.5 Trabalhos relacionados

Os conceitos revisados até aqui são usados extensivamente nos trabalhos da literatura que abordam o contexto de diagnóstico de úlceras em membros inferiores, de acordo com diversos pesquisadores. Em particular, o trabalho de Dorileo et al. (2008) aborda a importância da padronização das amostras de úlceras em um modelo de cores. Bedo et al. (2015) utilizam o paradigma supervisionado para o diagnóstico das imagens levantadas por Dorileo et al. (2008) e realizam um comparativo entre as características das imagens, a fim de apresentar a melhor forma para classificar imagens de úlceras.

Godeiro et al. (2018) utilizam uma redução de espaço de cor para a extração de regiões feridas de acordo com seus tecidos mais dominantes. Mukherjee et al. (2014) aplicam extratores de cores de baixo nível para transformar partes da imagem em pontos multidimensionais e aplica o classificador SVM para a rotular feridas crônicas. Blanco et al. (2016) usam o conjunto de dados de Dorileo et al. (2008), mas aplicam uma estratégia de divisão e conquista na qual as feridas são segmentadas com o apoio de métodos de construção de superpixels SLIC e os superpixels são representados em espaços de múltiplas dimensões por descritores MPEG-7 (BLANCO et al., 2016). Já Chino et al. (2018) utilizam o classificador RandomForest e o extrator “Bag-of-Signatures”. Por último Nejati et al. (2018) usam características oriundas de redes neurais de aprendizado profundo e o classificador SVM.

Tabela 4 – Trabalhos relacionados revisados.

<b>Autor &amp; Ano</b>	<b>Extrator de característica</b>	<b>Classificador</b>	<b>Precisão</b>
Pereyra et al. (2014)	Matrizes de co-ocorrência de cor	kNN	75,00%
Blanco et al. (2016)	3S-Measure	<i>RandomForest</i>	86,81%
Chino et al. (2018)	Nenhum	<i>RandomForest</i>	89,00%
Nejati et al. (2018)	AlexNet e ImageNet	<i>SVM</i>	86,40%

## 2.6 Conclusões parciais

Esse trabalho consiste no estudo e implementação de técnicas computacionais de processamento de imagens e aprendizado de máquina. Portanto, espera-se tirar proveito dos resultados e avanços relatados em trabalhos anteriores, para identificar e segmentar as imagens de úlceras em membros inferiores. Nesse sentido, técnicas clássicas de processamento de imagens são úteis para auxiliar e melhorar os resultados da segmentação entre o fundo da imagem e lesão. Essa separação pode ser finalizada por uma tarefa de limiarização ou classificação. Outra abordagem a ser avaliada na sequência é distinguir entre grupos, ou tecidos, dentro da lesão em si. A literatura traz relatos do uso eficiente de métodos de superpixel para essa etapa.

Uma vez que seja possível dividir a lesão em *superpixels* candidatos, estas regiões, com o valor médio do superpixel em espaço de cor adequado, podem ser agrupadas por um algoritmo particional, como o DBSCAN. Conclui-se que separar planos de fundos de pele e, depois disso, distinguir os tipos de tecidos envolvidos com a caracterização de úlceras em membros inferiores requer combinar várias, senão todas, as técnicas revisadas nessa seção.



### 3 Material e Métodos

Este capítulo aborda o protocolo de aquisição das imagens utilizadas para a análise e validação da proposta desse trabalho. O conjunto de dados é o mesmo empregado em trabalhos relacionados, o que facilita a comparação da técnica desenvolvida com outros resultados encontrados na literatura. Os recursos computacionais necessários para a implementação também são discutidos, com a finalidade de contribuir de forma transparente com a comunidade científica e facilitar a replicabilidade desse trabalho por interessados. Nesse sentido, toda a implementação e dados usados nos experimentos foram disponibilizados em um repositório público<sup>3</sup> e podem ser obtidos por quaisquer usuários cadastrados no repositório.

O capítulo se foca nos métodos desenvolvidos para a segmentação das úlceras em membros inferiores que foram construídos e testados de forma próxima a incremental. Em um primeiro momento, foi desenvolvida uma solução *ad-hoc*, baseada exclusivamente em técnicas de processamento de baixo nível que se mostraram capazes de alcançar resultados interessantes para a separação entre fundo e pele. A abordagem *ad-hoc* foi avaliada em um pequeno conjunto de três imagens ulceradas e os resultados indicaram que uma solução estruturada, orientada a aprendizado de máquina, teria uma possibilidade de melhorar ainda mais o sucesso obtido.

Nesse sentido, em um segundo momento, foi proposta uma solução para segmentação de úlceras como uma abordagem em duas fases. A primeira delas é baseada em classificação e permite separar fundo e pele, lesionada ou não. Já a segunda parte possibilita aglutinar pedaços de tecidos similares que podem ser divididos entre lesão, cicatrização, pele saudável e outros. As próximas seções apresentam a abordagem *ad-hoc*, os resultados obtidos para segmentação e indícios de adequabilidade para o uso de técnicas de aprendizado de máquina e, finalmente, o método em duas fases proposto para a segmentação completa de úlceras.

#### 3.1 Material: Conjunto de Dados e Ferramentas

Nesse trabalho foi usado o conjunto `ULCER_SET`, gerado por Dorileo et al. (2008) e Pereira et al. (2011). Esse conjunto de imagens foi coletado de pacientes não-parentes por dermatologistas do Hospital das Clínicas da Universidade de São Paulo em Ribeirão Preto/SP (HC-FMRP-USP). As fotografias coloridas de úlceras foram padronizadas de acordo com duas características: (i) plano de fundo – foi usado um pano ou azul ou branco, e (ii) uma régua de cores. A cor escolhida para o plano de fundo tem a finalidade de proporcionar contraste entre a pele do paciente e o fundo da imagem, de maneira a simplificar a tarefa de segmentação em uma técnica parecida com a *croma key*. Já a régua de cor foi usada com a finalidade de permitir a calibragem das cores em diferentes equipamento de projeções (PEREIRA et al., 2011).

As imagem resultantes, no entanto, apresentam diversas dificuldades para o processamento. Por exemplo, o fundo da imagem, ainda que azul ou branco, apresenta oscilação nas tonalidades de “azul” e “branco” e há uma irregularidade relacionada a distância da câmera ao membro

---

<sup>3</sup> <[github.com/sswellington/2PLA](https://github.com/sswellington/2PLA)>

inferior e o foco em torno das fotografias. A câmera digital utilizada para obtenção das imagens foi a da fabricante Canon Inc, modelo EOS 5D0, com a seguinte caracterização: Dois megapixels, lente macro de 50 mm e um filtro de polarização. A imagem resultante desta câmera possui tamanho de  $1747 \times 1165$  *pixels* com 24-bits de profundidade (DORILEO et al., 2008).

## 4 Experimentos e Resultados

Este capítulo apresenta os experimentos realizados para a avaliação da proposta 2PLA detalhada na Seção 3 e discute os resultados obtidos. Foram avaliados diversos cenários, sempre considerando o conjunto de dados `ULCER_SET` e sua segmentação realizada por especialistas.

A primeira etapa do processo de avaliação consistiu na definição do conjunto de dados rotulado para o treinamento do classificador da primeira fase do 2PLA. Na sequência, diversos classificadores foram avaliados para o processamento do conjunto de dados rotulados, sendo empregadas diversas métricas de qualidade para definir a melhor abordagem de classificação. Os próximos experimentos foram realizados para determinar os parâmetros mais adequados para a execução do algoritmo DBSCAN. Em particular, foram avaliadas cinco funções de distância que possuem diferentes perspectivas geométricas e o resultado foi quantificado em função do limite de similaridade máximo tolerado pelo DBSCAN. O último exame sobre a qualidade da proposta foi usar o método 2PLA com o melhor classificador, com o melhor limite de similaridade e melhor função de distância (todos obtidos experimentalmente) para segmentar imagens reais do conjunto `ULCER_SET`, sendo que o resultado obtido foi justaposto à segmentações manuais realizada por um especialista.

Todos os experimentos foram realizados em uma máquina local com a seguinte configuração: Sistema Operacional Linux Ubuntu 18.04.1 LTS<sup>4</sup> com um processador *i3* – 2310M 2.1 Ghz de 04 núcleos, equipado com 06Gb de memória RAM. Os conjuntos de dados avaliados e/ou gerados para a definição da parametrização do sistema se encontram publicamente disponíveis no mesmo repositório do código-fonte da solução<sup>5</sup>.

## 5 Conclusão

Neste trabalho foram aplicadas técnicas de processamento de imagens digitais e aprendizado de máquina com o objetivo de desenvolver uma ferramenta CAD especializada capaz de auxiliar no diagnóstico e acompanhamento de úlceras em membros inferiores à partir de fotografias das lesões. Ao contrário das abordagens existentes, as propostas desse trabalho consideram que a área em volta da lesão e os tecidos não lesionados são igualmente importantes para o tratamento da ulceração. Por exemplo, os tecidos na borda da lesão podem indicar que a úlcera está cicatrizando “rápido” demais ou que a lesão está gerando um excesso de umidade no local. Essas informações não são úteis para a detecção dos tipos dos tecidos lesionados em si, mas são de grande importância para o acompanhamento do procedimento terapêutico realizado pelo dermatologista ou outro profissional da saúde.

Não obstante, durante os estudos realizados foi detectado que seria desejável restringir o volume de dados a ser analisado para apenas a região de derme (lesionada ou não) para diminuir os custos computacionais associados ao processamento de imagens. Portanto, uma primeira

---

<sup>4</sup> <[releases.ubuntu.com/18.04/](https://releases.ubuntu.com/18.04/)>

<sup>5</sup> <[github.com/sswellington/2PLA/tree/master/dataset](https://github.com/sswellington/2PLA/tree/master/dataset)>

necessidade mais objetiva detectada foi a remoção da área do fundo da imagem (lençóis, etc.) da área de interesse (pele dos pacientes). Essa tarefa é particularmente desafiadora, pois deve-se remover dados inúteis, porém com a menor taxa de erro possível para que não haja interferência no resultado final da segmentação.

Uma primeira solução para a remoção do fundo, foi o projeto de uma solução *ad-hoc*, composta de uma conversão de imagem colorida no padrão RGB para uma imagem em tons de cinza. Nessa transformação, após testes para determinar a influência de cada uma das componentes de cor, os pesos das componentes cromáticas foram definidos de forma arbitrária de modo que apenas a área de interesse se tornasse visível com a aplicação de uma máscara. A separação da imagem em duas classes (fundo e pele) foi obtida com o uso de uma técnica de binarização com limiar, calculado automaticamente pelo método de Otsu. Como esperado para essa metodologia, a imagem resultante apresentou ruídos que foram removidos por filtros de processamento de imagens baseados em morfologia matemática.

Embora os resultados dessa metodologia *ad-hoc* tenham apresentado alguma eficiência em segmentar a pele do fundo da imagem, foi verificado que ao se fazer uso de um único limiar há a perda de trechos da imagem erroneamente identificados como fundo. Para remover essa característica indesejada de um único ponto de corte, uma nova técnica de segmentação foi adotada – o uso de classificadores oriundos do aprendizado de máquina. Esses métodos permitem definir múltiplos critérios de corte que, dentro de algumas perspectivas, podem ser vistos como múltiplos limiares. Os filtros de suavização morfológica foram mantidos ao final do processo de classificação pixel-a-pixel.

Como método de aprendizado de máquina, foram testados seis classificadores, sendo eles: Naïve-Bayes, Bayes-Net,  $k$ -Nearest Neighbor, Multi-Layer Perceptron (MLP), DecisionTree, RandomTree e RandomForest. Desses, por meio de avaliação de qualidade baseada no coeficiente de Cohen-Kapa e curva ROC, a MLP se mostrou muito mais eficaz para classificar pixels entre pele e fundo da imagem. Essa abordagem foi, então, adotada como a primeira fase do método final proposto nesse trabalho, o 2PLA. Uma vez selecionada a área de interesse, o próximo passo do 2PLA consiste em separar regiões de pele saudável de regiões lesionadas. Para tanto, aplica-se o método SLIC para agrupar pixels similares em superpixels com bordas bem definidas. Esses superpixels podem ser representados em um espaço tridimensional dado pelo modelo de cores LAB, de forma que torna-se possível agrupá-los de acordo com a sua densidade no espaço multidimensional pelo algoritmo particional DBSCAN.

Portanto, o maior desafio nessa segunda fase do 2PLA é encontrar o ajuste da parametrização adequada para o método DBSCAN. Foram analisadas cinco funções de distâncias métricas, sendo a  $L_1$  a função de distância mais “estável”, no sentido de produzir sempre menos grupos para todas as imagens avaliadas. Na sequência, as avaliações empíricas mostraram que o número de grupos resultantes da aplicação do método DBSCAN sobre superpixels de imagens de

úlceras é uma função de decaimento exponencial em relação ao limiar de similaridade. Com isso, foi usado o critério do “cotovelo” (similar ao usado para o *Scree-Plot* no método de análise de componentes principais) para se fixar o valor de similaridade de 3% da distância máxima no espaço unitário de cores a ser usado pelo DBSCAN.

O método 2PLA ajustado com o classificador MLP e o método de agrupamento DBSCAN com função  $L_1$  e limite de similaridade de 3% foi aplicado sobre um conjunto real de úlceras em membros inferiores que já havia sido segmentado manualmente por especialistas da área. Assim, foi possível comparar as segmentações geradas pela solução proposta nesse trabalho contra especialistas do domínio. Para o conjunto de imagens avaliadas, o 2PLA obteve um Erro Absoluto Médio de apenas 0,05 (variância de 0,01), o que permite concluir que as segmentações automáticas alcançaram resultados próximos aos dos especialistas humanos.

Como conclusão final, o método 2PLA proposto empregou uma combinação de técnicas de aprendizado supervisionado e não-supervisionado capazes de segmentar regiões de úlcera em membros inferiores e fornecendo resultados e observações empíricas que podem ser usadas por trabalhos relacionados em um futuro próximo.

## 5.1 Dificuldades Encontradas

Na execução desse trabalho foram superadas diversas dificuldades, tais como:

1. *Seleção dos métodos.* Uma vez que não há indicação clara na literatura de quais métodos (ou abordagens) são os mais eficientes para o processamento de imagens de úlceras, foi necessário um estudo aprofundado das metodologias aplicáveis ao problema.
2. *Cronograma de atividades.* Os temas necessários para realização da pesquisa eram “cíclicos”, sendo necessário revisar diversos conceitos de forma paralela.
3. *Framework de implementação.* Foram testadas várias plataformas de implementação e linguagens de programação, como C++, antes que fosse identificada a mais adequada ao propósito do trabalho (Matlab). Portanto, algumas partes do trabalho precisaram ser adaptadas ou reescritas algumas vezes.
4. *Tempo de Execução.* Alguns testes requisitaram grande esforço computacional, levando horas até que resultados pudessem ser apreciados. Isso fez com que a identificação de ajustes necessários ao trabalho levassem dias para serem realizados.
5. *Biblioteca/Espaço de Estudos.* O acervo da biblioteca do INFES contempla apenas livros-texto das disciplinas obrigatórias. Frequentemente, alguns assuntos necessários ao desenvolvimento desse trabalho não estavam disponibilizados. Além disso, ocorreram múltiplas greves e paralisações que afetaram o funcionamento da biblioteca.



## 5.2 Publicação

Os resultados principais decorrentes desse trabalho foram publicados em uma conferência internacional de impacto nas áreas de Computação e Informática Biomédica. O artigo foi apresentado no dia dois de junho de 2019 na Espanha, mas o D.O.I. (*Digital Object Identifier*) da publicação ainda não se encontra livremente disponibilizado na internet<sup>6</sup>. A citação completa do artigo, por enquanto, é como se segue.

- Silva, Wellington S.; Jasbick, Daniel L.; Wilson, Rodrigo E.; Azevedo-Marques, Paulo M.; Traina, Agma J. M.; Santos, Lucio F. D.; Jorge, Ana E. S.; Oliveira, Daniel; Bedo, Marcos V. N. *A Two-Phase Learning Approach for the Segmentation of Dermatological Wounds*. In: *Proceedings of 32nd International Symposium on Computer-Based Medical Systems*. Cordoba – ESP: IEEE. v. 1, p. 1–6.

Além dessa publicação, os resultados iniciais obtidos com o método *ad-hoc* foram submetidos em relatório técnico PROAES/UFF do projeto “*Implementação de extratores de características para imagens de úlcera venosa*” de 2017.

## 5.3 Premiação

Os resultados desse trabalho foram reportados na forma de um relatório e um artigo científico, apresentados na V Semana de Desenvolvimento Acadêmico da UFF e no 32º Congresso CBMS, respectivamente. Ambos os trabalhos foram premiados pelas comissões técnicas avaliadoras dos eventos, como se segue.

1. **(Convite para re-apresentação na Semana Nacional de Tecnologia – INFES)** – Implementação de extratores de característica para imagens de úlcera venosa. *V Semana de Desenvolvimento Acadêmico*. S. A. Pádua: Pró-Reitoria de Assuntos Estudantis, 2017
2. **(Menção Honrosa – Finalist Paper)** – A Two-Phase Learning Approach for the Segmentation of Dermatological Wounds. *32º International Symposium on Computer-Based Medical Systems*. Cordoba/ESP, 2019.

## 5.4 Trabalhos Futuros

O estudo e as avaliações experimentais desse trabalho serão usados como base para estender a investigação sobre imagens de úlceras dermatológicas. Em particular, como trabalhos futuros, pretende-se investigar as seguintes vertentes derivadas dessa pesquisa:

- *Comparar o método DBSCAN com outros métodos de agrupamento como a segunda fase da solução 2PLA*. Outros métodos de agrupamento, em especial aqueles baseados

---

<sup>6</sup> <https://www.doi.org/>

em grafos, podem ser usados como a segunda fase da solução 2PLA. Determinar qual método é o mais adequado para esse domínio requer avaliação teórica e experimental dos algoritmos comparados.

- *Rotular os tecidos afetados.* As regiões segmentadas pelo 2PLA podem ser automaticamente rotuladas por classificadores treinados com exemplos de fibrina, necrose, tecidos de borda calosa e outros.
- *Construir um aplicativo para hospedar a solução 2PLA.* O método 2PLA pode ser incorporado diretamente em um aplicativo móvel que capture fotos de úlceras em membros inferiores e as analise automaticamente.
- *Sugerir tratamentos baseados em diagnósticos similares.* A saída do método 2PLA permite obter uma imagem estruturada em trechos de diferentes tipos de lesão. Essa estrutura pode ser usada para comparar a fotografia analisada com imagens laudadas e previamente armazenadas em um banco de dados.

## Referências

ABBADE, L. P. F.; LASTORIA, S. Venous ulcer: epidemiology, physiopathology, diagnosis and treatment. *International Journal of Dermatology*, v. 44, n. 6, p. 449–456, jun 2005. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1365-4632.2004.02456.x>>.

ACHANTA, R. et al. SLIC superpixels compared to state-of-the-art superpixel methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 34, n. 11, p. 2274–2281, nov 2012. Disponível em: <<http://ieeexplore.ieee.org/document/6205760/>>.

AGGARWAL, C. C. *Data mining: The Textbook*. Springer, 2015. ISBN 978-3-319-14142-8. Disponível em: <<https://rd.springer.com/book/10.1007/978-3-319-14142-8>>.

AHMED, N.; NATARAJAN, T.; RAO, K. R. Discrete cosine transform. *Transactions on Computers, IEEE*, v. 100, n. 1, p. 90–93, 1974. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/1672377>>.

BEDO, M. V. N. et al. Color and Texture Influence on Computer-Aided Diagnosis of Dermatological Ulcers. In: *International Symposium on Computer-Based Medical Systems*. IEEE, 2015. p. 109–114. ISBN 978-1-4673-6775-2. Disponível em: <<http://ieeexplore.ieee.org/document/7167468/>>.

BLANCO, G. et al. A Label-Scaled Similarity Measure for Content-Based Image Retrieval. In: *International Symposium on Multimedia*. IEEE, 2016. p. 20–25. ISBN 978-1-5090-4571-6. Disponível em: <<http://ieeexplore.ieee.org/document/7823581/>>.

BONACCORSO, G. *Machine Learning Algorithms, Popular algorithms for data science and machine learning, 2nd Edition*. Packt Publishing Ltd, 2018. ISBN 9781789347999. Disponível em: <[https://subscription.packtpub.com/book/big\\_data\\_and\\_business\\_intelligence/9781789347999](https://subscription.packtpub.com/book/big_data_and_business_intelligence/9781789347999)>.

BOUTELL, T. *PNG (Portable Network Graphics) Specification Version 1.0*. [S.l.], 1997. Disponível em: <<https://www.rfc-editor.org/info/rfc2083>>.

BRADLEY, A. P. The use of the area under the ROC curve in the evaluation of machine learning algorithms. *Pattern Recognition*, 1997. Disponível em: <<https://www.sciencedirect.com/science/article/abs/pii/S0031320396001422>>.

CHANG, Y.-C.; REID, J. F. RGB calibration for color image analysis in machine vision. *Transactions on Image Processing*, IEEE, v. 5, n. 10, p. 1414–1422, Oct 1996. Disponível em: <<http://ieeexplore.ieee.org/document/536890/>>.

CHINO, D. Y. T. et al. ICARUS: Retrieving Skin Ulcer Images through Bag-of-Signatures. In: *International Symposium on Computer-Based Medical Systems*. IEEE, 2018. p. 82–87. ISBN 978-1-5386-6060-7. Disponível em: <<https://ieeexplore.ieee.org/document/8417217/>>.

CONGALTON, R. G.; GREEN, K. *Assessing the accuracy of remotely sensed data: principles and practices, 3rd Edition*. CRC Press, 2019. ISBN 978-1498776660. Disponível em: <[crcpress.com/Assessing-the-Accuracy-of-Remotely-Sensed-Data-Principles-and-Practices/Congalton-Green/p/book/9781498776660](http://crcpress.com/Assessing-the-Accuracy-of-Remotely-Sensed-Data-Principles-and-Practices/Congalton-Green/p/book/9781498776660)>.

CONNOLLY, C.; FLEISS, T. A study of efficiency and accuracy in the transformation from rgb to cielaab color space. *IEEE Transactions on Image Processing*, IEEE, v. 6, n. 7, p. 1046–1048, 1997. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/597279>>.

CORTEZ, P.; ROCHA, M.; NEVES, J. A lamarckian approach for neural network training. *Neural Processing Letters*, Springer, v. 15, n. 2, p. 105–116, 2002. Disponível em: <<https://link.springer.com/article/10.1023/A:1015259001150>>.

DOMINGOS, P. *The Master Algorithm: How the Quest for the Ultimate Learning Machine Will Remake Our World*. Basic Books, Inc., 2015. ISBN 9780465061921. Disponível em: <<https://www.basicbooks.com/titles/pedro-domingos/the-master-algorithm/9780465061921/>>.

DORILEO, E. A. G. et al. Segmentation and analysis of the tissue composition of dermatological ulcers. In: *23rd Canadian Conference on Electrical and Computer Engineering*. IEEE, 2010. p. 1–4. ISBN 978-1-4244-5376-4. Disponível em: <<http://ieeexplore.ieee.org/document/5575143/>>.

DORILEO, E. A. G. et al. Color image processing and content-based image retrieval techniques for the analysis of dermatological lesions. In: *International Conference of the IEEE Engineering in Medicine and Biology Society*. IEEE, 2008. p. 1230–1233. ISBN 978-1-4244-1814-5. Disponível em: <<http://www.ncbi.nlm.nih.gov/pubmed/19162888http://ieeexplore.ieee.org/document/4649385/>>.

ESTER, M. et al. A density-based algorithm for discovering clusters in large spatial databases with noise. In: *Conference on Knowledge Discovery and Data Mining*. [s.n.], 1996. v. 96, n. 34, p. 226–231. Disponível em: <<https://www.aaai.org/Papers/KDD/1996/KDD96-037.pdf>>.

ESTEVA, A. et al. Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, Springer Nature, v. 542, n. 7639, p. 115–118, Feb 2017. Disponível em: <<http://www.nature.com/articles/nature21056>>.

FACELI, K.; CARVALHO, A. C. de; SOUTO, M. C. de. Cluster ensemble and multi-objective clustering methods. In: *Pattern Recognition Technologies and Applications: Recent Advances*. IGI Global, 2008. p. 325–343. Disponível em: <<https://www.igi-global.com/chapter/cluster-ensemble-multi-objective-clustering/28037>>.

FELZENSZWALB, P. F.; HUTTENLOCHER, D. P. Efficient Graph-Based Image Segmentation. *International Journal of Computer Vision*, Springer, v. 59, n. 2, p. 167–181, Sep 2004. Disponível em: <<https://link.springer.com/article/10.1023/B:VISI.0000022288.19776.77>>.

GIL, J. Y.; KIMMEL, R. Efficient dilation, erosion, opening, and closing algorithms. *Transactions on Pattern Analysis and Machine Intelligence*, IEEE, v. 24, n. 12, p. 1606–1617, 2002. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/1114852>>.

GODEIRO, V. et al. Chronic wound tissue classification using convolutional networks and color space reduction. In: *28th International Workshop on Machine Learning for Signal Processing*. [S.l.]: IEEE, 2018. p. 1–6.

GONZALEZ, R. C.; WOODS, R. E. *Digital Image Processing, 3rd Edition*. Prentice hall. [s.n.], 2008. ISBN 9780131687288. Disponível em: <[http://www.imageprocessingplace.com/DIP-3E/dip3e\\_main\\_page.htm](http://www.imageprocessingplace.com/DIP-3E/dip3e_main_page.htm)>.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. Unsupervised learning. In: *The Elements of Statistical Learning*. Springer, 2009. ISBN 978-0-387-84858-7. Disponível em: <[https://link.springer.com/chapter/10.1007%2F978-0-387-84858-7\\_14](https://link.springer.com/chapter/10.1007%2F978-0-387-84858-7_14)>.

HECHT-NIELSEN, R. Applications of counterpropagation networks. *Neural Networks*, Elsevier, v. 1, n. 2, p. 131–139, 1988. Disponível em: <<https://www.sciencedirect.com/science/article/pii/0893608088900159>>.

HETLAND, M. L. The basic principles of metric indexing. In: *Swarm intelligence for multi-objective problems in data mining*. Springer, 2009. p. 199–232. ISBN 978-3-642-03625-5. Disponível em: <[https://link.springer.com/chapter/10.1007/978-3-642-03625-5\\_9](https://link.springer.com/chapter/10.1007/978-3-642-03625-5_9)>.

JAIN, A. K.; DUBES, R. C. Algorithms for clustering data. Englewood Cliffs: Prentice hall., 1988. Disponível em: <[http://homepages.inf.ed.ac.uk/rbf/BOOKS/JAIN/Clustering\\_Jain\\_Dubes.pdf](http://homepages.inf.ed.ac.uk/rbf/BOOKS/JAIN/Clustering_Jain_Dubes.pdf)>.

JAIN, A. K.; MAO, J.; MOHIUDDIN, K. M. Artificial neural networks: A tutorial. *Computers*, IEEE, v. 29, n. 3, p. 31–44, 1996. Disponível em: <<https://www.computer.org/csdl/magazine/co/1996/03/r3031/13rRUwInvNt>>.

JOHNSON, G. M.; FAIRCHILD, M. D. A top down description of s-cielab and ciede2000. *Color Research & Application*, Wiley Online Library, v. 28, n. 6, p. 425–435, 2003. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1002/col.10195>>.

KAPUR, J.; SAHOO, P.; WONG, A. A new method for gray-level picture thresholding using the entropy of the histogram. *Computer Vision, Graphics, and Image Processing*, v. 29, n. 3, p. 273–285, mar 1985. Disponível em: <<http://linkinghub.elsevier.com/retrieve/pii/0734189X85901252>>.

KAVITHA, I.; SUGANTHI, S. S.; RAMAKRISHNAN, S. Analysis of Chronic Wound Images Using Factorization Based Segmentation and Machine Learning Methods. In: *International Conference on Computational Biology and Bioinformatics*. ACM, 2017. p. 74–78. ISBN 978-1-4503-5322-9. Disponível em: <<https://dl.acm.org/citation.cfm?id=3155092>>.

- KWOK, T.-Y.; YEUNG, D.-Y. Constructive algorithms for structure learning in feedforward neural networks for regression problems. *Transactions on Neural Networks*, IEEE, v. 8, n. 3, p. 630–645, May 1997. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/572102>>.
- LI-SHENG, J. et al. An improved Otsu image segmentation algorithm for path mark detection under variable illumination. In: *Proceedings of Intelligent Vehicles Symposium*. IEEE, 2005. p. 840–844. ISBN 0-7803-8961-1. Disponível em: <<http://ieeexplore.ieee.org/document/1505209>>.
- LIPPMANN, R. An introduction to computing with neural nets. *American Society of Safety Professionals Magazine*, IEEE, v. 4, n. 2, p. 4–22, Apr 1987. Disponível em: <<https://ieeexplore.ieee.org/document/1165576>>.
- MAGLOGIANNIS, I.; PAVLOPOULOS, S.; KOUTSOURIS, D. An Integrated Computer Supported Acquisition, Handling, and Characterization System for Pigmented Skin Lesions in Dermatological Images. *IEEE Transactions on Information Technology in Biomedicine*, v. 9, n. 1, p. 86–98, mar 2005. Disponível em: <<http://ieeexplore.ieee.org/document/1402451>>.
- MCCAMY, C. S. et al. A color-rendition chart. *Journal of Applied Photograph Engineering*, v. 2, n. 3, p. 95–99, 1976. Disponível em: <<https://publiclab.org/system/images/photos/000/004/361/original/mccamy1976.pdf>>.
- MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, Springer, v. 5, n. 4, p. 115–133, 1943. Disponível em: <<https://link.springer.com/article/10.1007/BF02478259>>.
- MUKHERJEE, R. et al. Automated tissue classification framework for reproducible chronic wound assessment. *BioMed Research International*, Hindawi, v. 2014, p. 1–9, 2014. Disponível em: <<https://www.hindawi.com/journals/bmri/2014/851582/>>.
- MUMTAZ, K.; DURAISWAMY, K. Evaluation of the clustering characteristics of dbscan som and k-means algorithms. *International Journal of Computational Intelligence Research*, Research India Publications, v. 6, n. 4, p. 505–514, 2010. Disponível em: <<https://go.galegroup.com/ps/anonymouse?id=GALE%7CA323349393&sid=googleScholar&v=2.1&it=r&linkaccess=abs&issn=09731873&p=AONE&sw=w>>.
- NEJATI, H. et al. Fine-grained wound tissue analysis using deep neural network. In: IEEE. *International Conference on Acoustics, Speech and Signal Processing*. 2018. p. 1010–1014. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/8461927>>.
- ODUNCU, H. et al. Analysis of Skin Wound Images Using Digital Color Image Processing: A Preliminary Communication. *The International Journal of Lower Extremity Wounds*, v. 3, n. 3, p. 151–156, Sep 2004. Disponível em: <<https://doi.org/10.1177/1534734604268842>>.
- OTSU, N. A Threshold Selection Method from Gray-Level Histograms. *Transactions on Systems, Man, and Cybernetics*, v. 9, n. 1, p. 62–69, 1979. Disponível em: <<https://doi.org/10.1109/TSMC.1979.4310076>>.
- PEREIRA, S. M. et al. Classification of dermatological ulcers based on tissue composition and color texture features. In: *International Symposium on Applied Sciences in Biomedical and Communication Technologies*. ACM Press, 2011. p. 1–6. ISBN 9781450309134. Disponível em: <<http://dl.acm.org/citation.cfm?doid=2093698.2093766>>.

PEREYRA, L. C. et al. Characterization and pattern recognition of color images of dermatological ulcers: a pilot study. *Computer Science Journal of Moldova*, v. 22, n. 2, p. 211–235, 2014. Disponível em: <<https://pdfs.semanticscholar.org/782a/59a4acfcc0fdede7bf27e3f7f9e0139f61e1.pdf>>.

POWERS, D. M. W. Evaluation: from precision, recall and f-measure to roc, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, Bioinfo Publications, v. 2, n. 1, p. 37–63, 2011. Disponível em: <<http://hdl.handle.net/2328/27165>>.

PROVOST, F. J. et al. The case against accuracy estimation for comparing induction algorithms. In: *International Conference on Machine Learning*. [s.n.], 1998. v. 98, p. 445–453. Disponível em: <<https://pdfs.semanticscholar.org/7770/3a2783f64dfceb638aa9eebd9c9c501bb835.pdf>>.

RAMELET, A. A. Clinical Benefits of Daflon 500 mg in the Most Severe Stages of Chronic Venous Insufficiency. *Angiology*, v. 52, n. 1, p. 49–56, aug 2001. Disponível em: <<https://doi.org/10.1177/0003319701052001S07>>.

RIEDMILLER, M. Neural fitted q iteration—first experiences with a data efficient neural reinforcement learning method. In: SPRINGER. *European Conference on Machine Learning*. 2005. p. 317–328. Disponível em: <[https://link.springer.com/chapter/10.1007/11564096\\_32](https://link.springer.com/chapter/10.1007/11564096_32)>.

ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological Review*, American Psychological Association, v. 65, n. 6, p. 386–408, 1958. Disponível em: <<http://dx.doi.org/10.1037/h0042519>>.

RUSSELL, S. J.; NORVIG, P. *Artificial intelligence: a modern approach*. Pearson Education Limited, 2016. Disponível em: <[http://thuvienso.thanglong.edu.vn/handle/DHTL\\_123456789/4010](http://thuvienso.thanglong.edu.vn/handle/DHTL_123456789/4010)>.

SIM, J.; WRIGHT, C. C. The Kappa Statistic in Reliability Studies: Use, Interpretation, and Sample Size Requirements. *Physical Therapy*, v. 85, n. 3, p. 257–268, Mar 2005. Disponível em: <<http://dx.doi.org/10.1093/ptj/85.3.257>>.

SONKA, M.; HLAVAC, V.; BOYLE, R. *Image Processing, Analysis and Machine Vision*. 1. ed. Springer US, 1993. ISBN 978-0-412-45570-4. Disponível em: <<http://link.springer.com/10.1007/978-1-4899-3216-7>>.

SULLIVAN, W. *Machine Learning For Beginners Guide Algorithms, Supervised and Unsupervised Learning. Decision Tree & Random Forest Introduction*. [S.l.]: PublishDrive, 2017. ISBN 978-1-97563-232-8.

SUN, T.; NEUVO, Y. Detail-preserving median based filters in image processing. *Pattern Recognition Letters*, v. 15, n. 4, p. 341–347, apr 1994. Disponível em: <<http://linkinghub.elsevier.com/retrieve/pii/0167865594900825>>.

SURATGAR, A. A.; TAVAKOLI, M. B.; HOSEINABADI, A. Modified levenberg-marquardt method for neural networks training. *World Academy of Science, Engineering and Technology*, v. 6, n. 1, p. 46–48, 2005.

TAN, P.-N. et al. *Introduction to data mining*. [S.l.]: Pearson Education India, 2007.

TOWNSEND, J. T. Theoretical analysis of an alphabetic confusion matrix. *Perception & Psychophysics*, Springer, v. 9, n. 1, p. 40–50, 1971.

VEDALDI, A.; SOATTO, S. Quick shift and kernel methods for mode seeking. In: SPRINGER. *European Conference on Computer Vision*. [S.l.], 2008. p. 705–718.

WANG, L. *Support vector machines: theory and applications*. Springer Science & Business Media, 2005. ISBN 978-3-540-32384-6. Disponível em: <<https://www.springer.com/gp/book/9783540243885>>.

YU, H.; WILAMOWSKI, B. M. Levenberg-marquardt training. *Industrial Electronics Handbook*, CRC Press Boca Raton, FL, v. 5, n. 12, p. 1–16, 2011. Disponível em: <[http://www.eng.auburn.edu/~wilambm/pap/2011/K10149\\_C012.pdf](http://www.eng.auburn.edu/~wilambm/pap/2011/K10149_C012.pdf)>.

ZHANG, G.; PATUWO, B. E.; HU, M. Y. Forecasting with artificial neural networks:: The state of the art. *International Journal of Forecasting*, Elsevier, v. 14, n. 1, p. 35–62, 1998. Disponível em: <[https://doi.org/10.1016/S0169-2070\(97\)00044-7](https://doi.org/10.1016/S0169-2070(97)00044-7)>.

ZHANG, G.-m.; CHEN, S.-p.; LIAO, J.-n. Otsu image segmentation algorithm based on morphology and wavelet transformation. In: *International Conference on Computer Research and Development*. IEEE, 2011. p. 279–283. ISBN 978-1-61284-839-6. Disponível em: <<http://ieeexplore.ieee.org/document/5764020/>>.

ZHANG, X.; WANDELL, B. A. et al. A spatial extension of cielab for digital color image reproduction. In: SOCIETY FOR INFORMATION DISPLAY. *International symposium digest of technical papers*. 1996. v. 27, p. 731–734. Disponível em: <<http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.65.3462&rep=rep1&type=pdf>>.

ZHU, N. et al. A Fast 2D Otsu Thresholding Algorithm Based on Improved Histogram. In: *Chinese Conference on Pattern Recognition*. IEEE, 2009. p. 1–5. ISBN 978-1-4244-4199-0. Disponível em: <<http://ieeexplore.ieee.org/document/5344078/>>.